


Pràctica de Regressió Lineal amb la base de dades "Brain Cancer Data".

Objectius de la pràctica:

1. Treballar amb la base de dades Brain Cancer Data.
 - Suposarem que és un problema que ens han encarregat resoldre i proporcionarem:
 - A. Propietats de les variables observades i com es relacionen amb el temps de supervivència.
 - B. Explicació de com les variables observades afecten la variable de supervivència.
 - C. Crearem un predictor de temps de supervivència.
2. Aprendre a fer "Exploratory Data Analysis" (EDA), per entendre la base de dades i el problema a resoldre.
3. Resoldre el problema fent servir una tècnica simple i intuïtiva, Regressió lineal.

Esquema del procés de treball en Aprenentatge Automàtic.



1. Descripció del problema:

Objectiu

Estudi sobre el temps de supervivència per a pacients amb tumors cerebrals primaris que van rebre tractament amb mètodes de radioteràpia estereotàctica a l'Institut de Càncer Masaryk Memorial Brno (veure [1]). Identificant factors de risc i característiques, i la seva influència en el temps de supervivència.

Especificacions

1. Estudiar composició de la base de dades.
2. Entendre la relació entre les mesures i les dades de supervivència,
3. Veure la distribució de les variables i com les seves estadístiques poden influir en el temps de supervivència.
4. Analitzar el predictor resultant, per entendre com s'explica el temps de supervivència.

Bibliografia

- [1] Selingerova, I., Dolezelova, H., Horova, I., Katina, S., & Zelinka, J. (2016). Survival of patients with primary brain tumors: Comparison of two statistical approaches. PLoS One, 11(2), e0148733.
- <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4749663/>

1.1. Variables de la base de dades

Variable	Descripció de variable
sex	Factor amb nivells "Dona" i "Masculí"


| **diagnosis** | Factor amb nivells "Meningioma", "glioma LG", "glioma HG" i "Altres". | **loc** | Factor de localització amb nivells "Infratentorial" i "Supratentorial". | **ki** | Índex de Karnofsky. | | **gtv** | Volum tumoral brut, en centímetres cúbics. | | **stereo** | Factor mètode estereotàctic amb nivells "SRS" i "SRT". | | **status** | Si el pacient encara està viu al final de l'estudi. 0=Sí, 1=No. | | **time** | Temps de supervivència, en mesos |

1.2. Explicació de les variables

1.2.1. Índex de Karnofsky

ki: És una eina utilitzada per avaluar l'estat funcional dels pacients amb càncer. Va ser desenvolupat pels doctors Karnofsky i Burchenal l'any 1949. Aquest índex mesura la **capacitat del pacient per realitzar les activitats de la vida diària i la seva capacitat de treball**. És una eina àmpliament utilitzada en oncologia per avaluar el pronòstic del pacient i la resposta al tractament.

1.2.1. Variables diagnosi i localització:



Radioteràpia Estereotàctica

La radioteràpia estereotàctica és una forma molt precisa de radioteràpia utilitzada per tractar tumors i altres anomalies al cos. Implica l'ús de múltiples feixos de radiació que convergeixen en un objectiu específic, proporcionant una alta dosi de radiació a l'àrea afectada, alhora que es minimitza el dany al teixit saludable circumdant.

Hi ha dos tipus principals de radioteràpia estereotàctica:

1. **Cirurgia radiològica estereotàctica (SRS):** Normalment s'utilitza per tractar petits tumors al cervell i altres parts del cos. Sovint es completa en una única sessió.
2. **Radioteràpia corporal estereotàctica (SBRT):** S'utilitza per tractar tumors en el cos, com en els pulmons, fetge, columna vertebral i altres teixits tous. Normalment implica múltiples sessions.

Ambdues metodologies utilitzen tècniques d'imatges avançades per dirigir-se amb precisió al tumor, assegurant un impacte mínim en els teixits saludables.

Diferències entre SRS i SRT

Característica	SRS (Radiocirurgia estereotàctica)	SRT (Radioteràpia estereotàctica)
Dosificació	Dosi alta en una sola sessió	Dosi fraccionada en diverses sessions
Mida de la diana	Petites dianes ben definides	Dianes més grans o de formes irregulars
Precisió	Extremadament alta	Alta, però ajustada per la fraccionació
Durada	Un sol dia	De dies a setmanes
Aplicacions	Metàstasis cerebrals, MAV, tumors petits	Tumors més grans o prop d'estructures crítiques

Exercici 1

1. Per tal de clarificar els objectius d'aquesta pràctica, redactar un paràgraf resumint el tipus de base de dades utilitzada i l'objectiu de la pràctica.
2. Abans d'aplicar mètodes d'Intel·ligència artificial, cal tenir una intuïció sobre com influencien les variables observacionals el resultat. A partir de la descripció de les variables escriu breument la llista de variables que poden augmentar o disminuir el temps de supervivència. Redactar una explicació d'una línia per justificar cada cas.

2. Regressió Lineal: Una Introducció Intuïtiva

2.1. Què és la Regressió Lineal?

La regressió lineal és un mètode estadístic per estimar la relació entre variables mitjançant una línia recta.

Metàfora: un procés de "combinar puntuacions relacionades" per predir un resultat.

2.1.1. Exemple: Calcular preu d'una casa

Calcular $f(x)$ = preu d'una casa on x és un vector d'observables.

Per predir el preu d'una casa, els factors que influeixen en el preu poden ser:

- Superfície de la casa
- Nombre d'habitacions
- Ubicació
- Antiguitat

La regressió lineal combinar aquests factors de manera ponderada per estimar el preu final.

2.1.2. Formulació Matemàtica

La fórmula de la regressió lineal és:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon$$

On:

- y és la variable que volem predir
- β_0 és el punt d'intercepció (valor base)
- $\beta_1, \beta_2, \dots, \beta_n$ són els coeficients (importància de cada factor)
- $x_1, x_2, \dots, x_n$ són els factors/variables
- ϵ representa l'error del model

2.1.3. Exemple de Combinació de Puntuacions

Pensem en el preu d'una casa:

- $\beta_0 = 50.000\text{€}$ (preu base)
- $\beta_1 = 200\text{€/m}^2$ (valor per metre quadrat)
- $\beta_2 = 10.000\text{€/habitació}$ (valor per habitació)

Si una casa té:

- 100m^2
- 3 habitacions

$$\text{Preu} = 50.000 + (200 \times 100) + (10.000 \times 3) = 50.000 + 20.000 + 30.000 = 100.000 \text{€}$$

3. Definició Formal de la Regressió Lineal.

Veure diagrama dibuixat a la pissarra

3.1. Què és la Regressió Lineal?

La **regressió lineal** és una tècnica estadística utilitzada per modelar la relació entre una variable dependent (y) i una o més variables independents (X_i). L'objectiu principal de la regressió lineal és ajustar una línia recta que millor representi la relació entre les variables, **minimitzant l'error** (veure eq. 1 mes abaix) entre els valors predits i els valors reals.

- **Fórmula de la Regressió Lineal:** $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$

On:

- y : Variable dependent (resposta o objectiu).

- $X_1, X_2, \dots, X_n$: Variables independents (predictors).
- β_0 : Intercept o terme constant.
- $\beta_1, \beta_2, \dots, \beta_n$: Coeficients que indiquen l'impacte de cada predictor sobre y .
- ϵ : Terme d'error (diferència entre els valors reals i els valors predits).

3.2. Com funciona?

La regressió lineal utilitza el mètode dels mínims quadrats per ajustar una línia als punts de dades. Això implica trobar els valors de β_0 i $\beta_1, \beta_2, \dots, \beta_n$ que minimitzin la suma dels quadrats de les diferències entre els valors reals (y) i els valors predits ($\hat{y}$).

Mètode d'Estimació: Mínims Quadrats

Per trobar els millors β , fem servir el mètode de mínims quadrats:

$$(1) \quad \min_{\beta} \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_n x_{ni}))^2$$

On:

- y_i : Resposta real per les observacions $X_1, X_2, \dots, X_n$.

Busquem minimitzar la diferència quadràtica entre els valors predits $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$ i reals y_i .

Veure Apendix 1 per Mètode d'Estimació dels coeficients $\beta_0, \beta_1, \beta_2, \dots, \beta_n$: per Mínims Quadrats

4. Part pràctica.

- Primer carreguem les llibreries de python
- Després carreguem la base de dades

```
In [3]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
from sklearn.linear_model import LinearRegression
import numpy as np
import os
```

Lectura de la base de dades.

```
In [4]: df_DataBase = pd.read_excel('BrainCancer.xlsx')
df_DataBase.drop(columns = ['Unnamed: 0'], inplace = True)
df_DataBase.head()
```

Out [4]:

	sex	diagnosis	loc	ki	gtv	stereo	status	time
0	Female	Meningioma	Infratentorial	90	6.11	SRS	0	57.64
1	Male	HG glioma	Supratentorial	90	19.35	SRT	1	8.98
2	Female	Meningioma	Infratentorial	70	7.95	SRS	0	26.46
3	Female	LG glioma	Supratentorial	80	7.61	SRT	1	47.80
4	Male	HG glioma	Supratentorial	90	5.06	SRT	1	6.30

Fem un comptatge de les combinacions de variables **qualitatives**.

In [5]: `df_DataBase[['sex','diagnosis','loc','stereo']].value_counts()`

Out[5]:

sex	diagnosis	loc	stereo	
Female	Meningioma	Supratentorial	SRT	16
Male	HG glioma	Supratentorial	SRT	13
	Meningioma	Supratentorial	SRT	10
Female	HG glioma	Supratentorial	SRT	7
	Meningioma	Infratentorial	SRS	6
		Supratentorial	SRS	5
Male	LG glioma	Supratentorial	SRT	5
	Meningioma	Supratentorial	SRS	4
Female	Other	Supratentorial	SRT	3
Male	Other	Infratentorial	SRT	3
			SRS	3
		Supratentorial	SRT	2
Female	Other	Infratentorial	SRT	2
	LG glioma	Supratentorial	SRS	2
Male	HG glioma	Infratentorial	SRS	1
	LG glioma	Infratentorial	SRT	1
	Meningioma	Infratentorial	SRT	1
Female	Other	Infratentorial	SRS	1
	Meningioma	Infratentorial	SRT	1
	LG glioma	Supratentorial	SRT	1
	HG glioma	Supratentorial	SRS	1

Name: count, dtype: int64

Fem un comptatge de les combinacions de variables **quantitatives**.

In [6]: `df_DataBase.describe()`

Out [6]:

	ki	gtv	status	time
count	88.000000	88.000000	88.000000	88.000000
mean	81.022727	8.660795	0.397727	27.457500
std	10.508866	8.657576	0.492233	20.124412
min	40.000000	0.010000	0.000000	0.070000
25%	80.000000	2.500000	0.000000	10.392500
50%	80.000000	6.510000	0.000000	24.030000
75%	90.000000	12.100000	1.000000	41.597500
max	100.000000	34.640000	1.000000	82.560000

Exercici 2

1. Expliqui breument (dos línies) la informació que proporcionen les instruccions: `df_DataBase.describe()` i `df_DataBase['diagnosis'].value_counts()`.
2. Hem fet servir l'instrucció: `df_DataBase['diagnosis'].value_counts()`.
 - Què podeu dir sobre la seva fiabilitat de les combinacions, per estimar les probabilitats de resultats?

4.1. Anàlisi exploratòria de dades (EDA)

4.1.1. Estructura del DataFrame.

Metafora: un full excel.

Analitzem l'estructura i les dades resum del conjunt de dades per comprendre les seves columnes i els tipus de dades que contenen.

Recordar que EDA és important per a [l'informe Final i Recomanacions](#) que es presenten al final dels estudis.

```
In [7]: print('_'*50)
print('* Observar que té estructura excel, amb capçalera amb \n noms de v
print('_'*50)
df_DataBase.head()
```

* Observar que té estructura excel, amb capçalera amb
noms de variables i enumeració d'exemples

Out [7]:

	sex	diagnosis	loc	ki	gtv	stereo	status	time
0	Female	Meningioma	Infratentorial	90	6.11	SRS	0	57.64
1	Male	HG glioma	Supratentorial	90	19.35	SRT	1	8.98
2	Female	Meningioma	Infratentorial	70	7.95	SRS	0	26.46
3	Female	LG glioma	Supratentorial	80	7.61	SRT	1	47.80
4	Male	HG glioma	Supratentorial	90	5.06	SRT	1	6.30

In [8]: `# Estructura bàsica i tipus de dades`
`df_DataBase.info()`

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 88 entries, 0 to 87
Data columns (total 8 columns):
#   Column      Non-Null Count  Dtype
---  -
0   sex         88 non-null    object
1   diagnosis   88 non-null    object
2   loc         88 non-null    object
3   ki          88 non-null    int64
4   gtv         88 non-null    float64
5   stereo      88 non-null    object
6   status      88 non-null    int64
7   time        88 non-null    float64
dtypes: float64(2), int64(2), object(4)
memory usage: 5.6+ KB
```

Exercici 3

1. Si fem servir un mètode per predir el temps basat en una combinació lineal del tipus:

- $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$
- $time = \beta_0 + \beta_1 sex + \beta_2 diagnosis + \beta_3 loc + \beta_4 ki + \beta_5 gtv + \beta_6 stereo + \beta_7 stat$
 - Quina transformació s'ha de fer sobre les dades perquè el format sigui acceptable per el software?. Pista: Dtype: object, es un "string".

4.1.2. Descripció general de les dades.

Estadístiques resumides de les variables numèriques.

El mètode `df_DataBase.describe()` és una funció en Python, dins de la llibreria Pandas, que proporciona un resum estadístic de les columnes numèriques d'un DataFrame:

- **count:** El nombre de valors no nuls en cada columna.
- **mean:** La mitjana aritmètica dels valors.
- **std:** La desviació estàndard dels valors.

- **min:** El valor mínim.
- **25%:** El percentil 25 (el valor per sota del qual es troba el 25% dels valors).
- **50%:** El percentil 50 (la mediana).
- **75%:** El percentil 75 (el valor per sota del qual es troba el 75% dels valors).
- **max:** El valor màxim.

Aquesta informació permet obtenir una primera visió general de les dades i **identificar possibles anomalies o tendències.**

```
In [9]: # Estadístiques descriptives per a les columnes numèriques
df_DataBase.describe().round(2)
```

```
Out [9]:
```

	ki	gtv	status	time
count	88.00	88.00	88.00	88.00
mean	81.02	8.66	0.40	27.46
std	10.51	8.66	0.49	20.12
min	40.00	0.01	0.00	0.07
25%	80.00	2.50	0.00	10.39
50%	80.00	6.51	0.00	24.03
75%	90.00	12.10	1.00	41.60
max	100.00	34.64	1.00	82.56

```
In [10]: # Estadístiques descriptives per a les columnes categòriques
df_DataBase.describe(include='object').round(2)
```

```
Out [10]:
```

	sex	diagnosis	loc	stereo
count	88	88	88	88
unique	2	4	2	2
top	Female	Meningioma	Supratentorial	SRT
freq	45	43	69	65

Exercici 4

1. Expliqui breument la informació que proporciona l'instrucció `df_DataBase.describe()`, per els casos `gtv` i `time`. Observar que la mitjana aritmètica i mediana (percentil 50%) són diferents, i les desviacions estandard són molt semblants a les mitjanes. Es coherent amb una distribució Gausiana?, Quina distribució estadística coneix que tingui aquesta propietat?
- **Atenció:** aquest apartat servirà per interpretar mes endavant la figura: Box Plot (diagrama en capces).

4.1.3. Estudi de la distribució de cada columna

1. *Columnes categòriques*: Identifiquem els valors únics i la seva freqüència per a cada columna categòrica.
2. *Columnes numèriques*: Visualitzem la distribució de les columnes numèriques mitjançant histogrames i diagrames de caixa.

```
In [11]: # Valors únics i freqüència
for col in ['sex', 'diagnosis', 'loc', 'stereo', 'status']:
    print(f"\nDistribució de valors per {col}: (percentatge)")
    print(df_DataBase[col].value_counts(normalize=True).round(4)*100)
```

Distribució de valors per sex: (percentatge)

sex

Female 51.14

Male 48.86

Name: proportion, dtype: float64

Distribució de valors per diagnosis: (percentatge)

diagnosis

Meningioma 48.86

HG glioma 25.00

Other 15.91

LG glioma 10.23

Name: proportion, dtype: float64

Distribució de valors per loc: (percentatge)

loc

Supratentorial 78.41

Infratentorial 21.59

Name: proportion, dtype: float64

Distribució de valors per stereo: (percentatge)

stereo

SRT 73.86

SRS 26.14

Name: proportion, dtype: float64

Distribució de valors per status: (percentatge)

status

0 60.23

1 39.77

Name: proportion, dtype: float64

Exercici 5

1. Expliqueu breument (un paràgraf) quina utilitat creieu que pot tenir l'instrucció anterior. Per exemple, podem veure que homes i dones estan igualment representats. Si creem un model amb aquesta base de dades, què podem dir sobre la fiabilitat d'aquest model amb "LG glioma" o "SRS"? (Suggerència un paràgraf)
2. Proposi un classificador per **status** que necessita una línia de codi i proporciona un 60.23% d'encerts.

4.1.4. Histograma (distribució de prob.).

- Nota: fem servir la llibria "seaborn" (<https://seaborn.pydata.org/examples/>)

• Histograma

- Un histograma és una representació aproximada de la distribució de dades numèriques. Va ser introduït per primera vegada per Karl Pearson. Per construir un histograma, el primer pas és "classificar" l'abast dels valors, és a dir, dividir l'abast complet dels valors en una sèrie d'interval, i després comptar quants valors cauen en cada interval.


- **Definició formal Histograma:** $\sum_{i=1}^n f(x_i)$

on $f(x_i)$ és la freqüència d'aparició del valor x_i en el conjunt de dades.

```
In [12]: fig, axes = plt.subplots(nrows=1, ncols=3, figsize=(14, 5))

for ax, col in zip(axes, ['ki', 'gtv', 'time']):
    sns.histplot(data=df_DataBase, x=col, bins=25, kde=True, ax=ax)

fig.suptitle('Distribució de variables numèriques')
plt.tight_layout()
plt.show()
```



Exercici 6

Observeu que els valors numèrics no semblen de cap manera gaussians, no hi ha un valor mig clar, i el concepte de desviació típica no té sentit en aquest cas.

1. Expliqueu amb paraules (tres línies) el que enteneu per valor mitjà, mediana i desviació estàndard
2. Expliqueu, a partir de la descripció anterior, per què aquests descriptius no tenen sentit en les variables: 'ki', 'gtv', 'time'.

- **Nota:** Una alternativa al millor és el diagrama de capces a continuació.
- **Nota:** Per estudiants avançats: fer una ullada a la llibreria seaborn: (<https://seaborn.pydata.org/examples/>).


4.1.5. Explicació del diagrama de capces (box plot)

El box plot, o diagrama de capces, és una eina gràfica utilitzada per representar la distribució d'una variable numèrica en un conjunt de dades.

Els percentils que es marquen en un diagrama de caixa són:

- El quartil inferior (Q1), que correspon al 25% de la mostra.
- La mediana (Q2), que correspon al 50% de la mostra.
- El quartil superior (Q3), que correspon al 75% de la mostra.
- Mediana: **línia horitzontal verda** representa la mediana, 50% de la mostra.
- Les línies horitzontals superior i inferior representen els valors Q1x1,5 i Q3x1,5. Els punts que es troben fora d'aquest rang s'anomenen punts atípics o outliers.
- Valor mitjà esta representat per un punt vermell.
- Valors extrems (Outliers) representats amb cercles.
- Aquests percentils divideixen la mostra en quatre parts iguals, de manera que el 25% inferior de la mostra es troba per sota del quartil inferior, el 25% superior de la mostra es troba per sobre del quartil superior, i la meitat de la mostra es troba entre el quartil inferior i el quartil superior.

```
In [13]: # Box Plot: diagrama en capces.
ax = df_DataBase[['ki', 'gtv', 'time']].boxplot(figsize=(8, 4), patch_art
# Títol
ax.set_title('Distribució de variables numèriques', fontsize=16, weight='
# Etiquetes en el eix x
ax.set_xticklabels(['KI', 'GTV', 'Time'], fontsize=12, rotation=0, weight
ax.set_ylabel('Valors', fontsize=12, weight='bold')
ax.yaxis.grid(True, linestyle='--', alpha=0.7)
plt.show()
```



Exercici 7

Objectiu d'aquest exercici: Entendre l'informació proporcionada pel BoxPlot

1. Descrigui amb paraules (un paràgraf) per cada variable, a partir del box plot, com es distribueixen les variables. Què vol dir que una observació estigui a més de 1,5 vegades la desviació estàndard (valor extrem)? Com es veu que la distribució és asimètrica?

4.1.6. Veurem si hi ha diferència entre homes i dones.

Interpretació de les variables.

KPS


- KPS 100: Aquest índex representa "normal; sense queixes; sense evidència de malaltia". El pacient pot dur a terme totes les activitats normals sense restriccions, indicant una salut perfecta o tan a prop com sigui possible en el context del tractament del càncer. No presenten símptomes ni signes de malaltia.
- KPS 40: En aquest nivell, el pacient es descriu com "incapacitat; necessita atenció especial i assistència". Estan significativament limitats en les seves activitats, sovint incapaços de realitzar tasques bàsiques de cura personal sense ajuda. Això indica un pacient amb símptomes greus o progressió de la malaltia, on podrien estar confinats al llit o a una cadira la major part del temps, necessitant una assistència i cura mèdica considerabl

GTV Comparació de tamanys en cm^3 per fer-se una idea del significat dels valors:

- Dau: $4cm^3$
- Pilota de golf: $40cm^3$ e.

```
In [14]: fig, axes = plt.subplots(nrows=1, ncols=3, figsize=(15, 5))
custom_palette = {"Male": "blue", "Female": "red"}
# Iterem per columnes i creem histogrames, diferenciant entre dona i home
for i, col in enumerate(['ki', 'gtv', 'time']):
    sns.histplot(data=df_DataBase, x=col, hue="sex", kde=False, ax=axes[i])
    axes[i].set_title(f"Histograma de {col}")

plt.tight_layout()
plt.show()
```




Exercici 8

Per cada variable faci una descripció breu de quines diferències hi ha entre homes i dones, en quan a valors de variables i temps de supervivència. Hi ha alguna diferència en quan a autonomia o volum del tumor?.

```
In [15]: print('Stereo: "SRS": Dosi alta en una sola sessió. "SRT": Dosi fraccionada')
print('Status: Si el pacient encara està viu al final. 0=Sí, 1=No. ')
fig, axes = plt.subplots(nrows=1, ncols=3, figsize=(15, 5))
custom_palette = {"Male": "blue", "Female": "red"}
# Iterem per columnes i creem histogrames, diferenciant entre dona i home
for i, col in enumerate(['diagnosis', 'stereo', 'status']):
    sns.histplot(data=df_DataBase, x=col, hue="sex", ax=axes[i], palette=custom_palette)
    axes[i].set_title(f"Histograma de {col}")

plt.tight_layout()
plt.show()
```

Stereo: "SRS": Dosi alta en una sola sessió. "SRT": Dosi fraccionada en diverses sessions
 Status: Si el pacient encara està viu al final. 0=Sí, 1=No.



Exercici 9


Per cada variable faci una descripció breu de quines diferències hi ha entre homes i dones, en quan a valors de variables i el significat segons les explicacions al principi de la pràctica.

```
In [16]: fig, axs = plt.subplots(1, 2, figsize=(8, 3))

sns.scatterplot(data=df_DataBase, x='ki', y='time', hue='sex', ax=axs[0])
axs[0].set_title('Scatterplot of ki vs. time')

sns.scatterplot(data=df_DataBase, x='gtv', y='time', hue='sex', ax=axs[1])
axs[1].set_title('Scatterplot of gtv vs. time')

# Show the plot
plt.show()
```



```
In [17]: # Mitjanes per grups
print(df_DataBase.groupby('sex')[['ki', 'gtv', 'time']].mean().round(1))
```

	ki	gtv	time
sex			
Female	80.2	7.6	28.1
Male	81.9	9.7	26.8

Exercici 10

Aquest exercici és per entendre els diagrames de dispersió (scatter plots).

1. Escriui en una línia quin tipus de representació és el diagrama de dispersió.
2. Existeix alguna relació funcional entre temps de supervivència, les variables ki, gtv i el sexe?
 - Recordar: | Variable | Descripció de variable | ---|---| | **sex** | Factor amb nivells "Dona" i "Masculi" | | **ki** | Índex de Karnofsky. | | **gtv** | Volum tumoral brut, en centímetres cúbics. |

5. Relacions entre variables

1. **Correlació entre columnes numèriques** Examinem la correlació entre les columnes numèriques per entendre relacions potencials.
2. **Anàlisi de grups per columnes categòriques** Examinem com varien les variables numèriques segons les categories.

5.1. Explicació intuïtiva de la fórmula de la correlació $r_{X,Y}$

La fórmula de la correlació, coneguda com el **coeficient de correlació de Pearson**, mesura la força i la direcció de la relació lineal entre dues variables, X i Y . Ara ho desglossem pas a pas:

1. Restar a cada punt la seva mitjana (desviacions)

- $(X_i - \bar{X})$: Calcula la diferència entre el valor X_i i la seva mitjana $\bar{X}$. Això indica com de lluny està X_i respecte al "centre" dels valors de X .
- $(Y_i - \bar{Y})$: Fa el mateix per Y .

Aquest pas **centra cada variable** respecte a la seva mitjana, eliminant l'efecte de biaix.

2. Producte de les desviacions

- El terme $(X_i - \bar{X})(Y_i - \bar{Y})$ és el producte de la desviació de cada entrada per la desviació de la sortida, tots dos respecte a la mitjana:
 - Si X_i i Y_i són alhora més grans o més petits que les seves respectives mitjanes, aquest producte és positiu (relació positiva).
 - Si un valor és més gran i l'altre més petit que la seva mitjana, el producte és negatiu (relació negativa).

Aquest producte indica com varien conjuntament X i Y .

3. Sumem els productes de desviacions

- $\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$: Suma aquests productes per obtenir una mesura acumulada de com X i Y estan relacionades.

Si la suma és gran i positiva, hi ha correlació positiva. Si és gran i negativa, hi ha correlació negativa.

4. Normalització (divisió per la desviació estàndard)

- **desviació estàndard de X** : $\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2}$.

- **desviació estàndard de Y :** $\sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}$.

Dividim la suma acumulada dels productes per aquests valors perquè:

1. Mesura adimensional independent de l'efecte de les **unitats**, per exemple, si X està en cm^3 i Y en mesos.
2. El resultat estigui comprès entre -1 i $+1$.


5. Resultat final

- $r_{X,Y} > 0$: Les variables es mouen en la mateixa direcció (correlació positiva).
- $r_{X,Y} < 0$: Les variables es mouen en direccions oposades (correlació negativa).
- $r_{X,Y} = 0$: No hi ha cap relació lineal entre X i Y .


Intuïció general

La fórmula calcula com de sincronitzades estan X i Y en el seu comportament, centrant-se només en la relació **lineal**. Si canviem l'escala o desplaçem les variables, el valor de $r_{X,Y}$ no canviarà perquè només mesura **la força relativa de la relació** entre elles.

- Exemple $r_{X,Y} > 0$:



- Exemple $r_{X,Y} = 0$:



Exercici 11

1. Descriu amb paraules, a partir de la figura superior, els passos que es segueixen en el càlcul de la funció de correlació. Expliqui què pot significar que

$(X_i - \bar{X})(Y_i - \bar{Y})$ tingui signes alternats i com això pot afectar el valor del coeficient de correlació $r_{X,Y}$.

5.2. Definició formal de la Funció de Correlació

El coeficient de correlació entre dues variables X i Y és el coeficient de correlació de Pearson r , que es calcula com:

$$r_{X,Y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

On:

- n és el nombre de parells de puntuacions.
- X_i i Y_i són els punts de mostra individuals indexats amb i .
- $\bar{X}$ i $\bar{Y}$ són les mitjanes de X i Y , respectivament.

Funció de Correlació per les variables: 'ki', 'gtv', 'time'.

Les respectives funcions de correlació son:

$$\rho_{ki,gtv} = \frac{\sum_{i=1}^n (ki_i - \bar{ki})(gtv_i - \bar{gtv})}{\sqrt{\sum_{i=1}^n (ki_i - \bar{ki})^2} \sqrt{\sum_{i=1}^n (gtv_i - \bar{gtv})^2}}$$

$$\rho_{ki,time} = \frac{\sum_{i=1}^n (ki_i - \bar{ki})(time_i - \bar{time})}{\sqrt{\sum_{i=1}^n (ki_i - \bar{ki})^2} \sqrt{\sum_{i=1}^n (time_i - \bar{time})^2}}$$

$$\rho_{gtv,time} = \frac{\sum_{i=1}^n (gtv_i - \bar{gtv})(time_i - \bar{time})}{\sqrt{\sum_{i=1}^n (gtv_i - \bar{gtv})^2} \sqrt{\sum_{i=1}^n (time_i - \bar{time})^2}}$$


On:

- ρ representa el coeficient de correlació de Pearson.
- ki_i , gtv_i i $time_i$ són els punts de mostra individuals per les columnes `ki`, `gtv` i `time`, del DataFrame.
- $\bar{ki}$, $\bar{gtv}$ i $\bar{time}$ són les mitjanes de les columnes `ki`, `gtv` i `time`, del DataFrame.

Nota: Observar que el coeficient és adimensional. **Nota:** El codi següent utilitza una primitiva de la llibreria "Seaborn".

5.2.1. Calcularem la matriu de correlació entre variables numèriques.

```
In [18]: # Matriu de correlació
corr_matrix = df_DataBase[['ki', 'gtv', 'time']].corr()
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm')
plt.title('Matriu de correlació')
plt.show()
```



Exercici 11

A partir de l'explicació del coeficient de correlació de Pearson, i el significat de les variables.


1. Expliqui que significa que **ki** estigui correlada positivament amb el temps de supervivència, i negativament amb el tamany del tumor.
 2. Expliqui que significa que el tamany del tumor estigui correlat negativament amb el temps de supervivència.
- Recordar: | Variable | Descripció de variable | |---|---| | **sex** | Factor amb nivells "Dona" i "Masculi" | | **ki** | Índex de Karnofsky. | | **gtv** | Volum tumoral brut, en centímetres cúbics. |

5.2.2. Diagrames "Box Plot" condicionat per el 'Status':

ki, gtv, time vs. diagnòstic, status

- Status: Si el pacient encara està viu al final de l'estudi. 0=Sí, 1=No.

```
In [19]: for num_col in ['ki', 'gtv', 'time']:
          g = sns.FacetGrid(df_DataBase, col='status', col_wrap=3, sharey=True)
          cat_order = df_DataBase['diagnosis'].dropna().unique()
          g.map(sns.boxplot, 'diagnosis', num_col, order=cat_order)
```



Exercici 12

1. Expliqui en un paràgraf, quina utilitat pot tenir representar els diagrames "Box Plot" factoritzat per condició 'Status':
2. Per cada mesura: ki, gtv, time indicar si hi ha algun diagnòstic que es relaciona més amb supervivència.

5.2.2. Anàlisi de la distribució del temps de supervivència estratificada per factors categòrics:


```
In [20]: # Definim el nombre de columnes per al subplot (ajusta segons sigui neces
num_cols = 3

# Creem una figura amb subplots d'amplada igual
fig, axes = plt.subplots(1, num_cols, figsize=(15, 5)) # Ajusta la mida

# Iterem a través de les variables de color
hue_vars = ['status', 'diagnosis', 'loc']
col_idx = 0
for hue_var in hue_vars:
    # Utilitzem el subplot actual de l'array
    ax = axes[col_idx]
    sns.histplot(ax=ax, data=df_DataBase, x='time', hue=hue_var, kde=True)
    ax.set_title(f"Distribució del temps segons {hue_var}")
    col_idx += 1

# Ajusta el layout (opcional)
plt.tight_layout()

# Mostra el gràfic
plt.show()
```



Exercici 13

Explicació de la dependència del temps de supervivència en cada una de les circumstàncies del pacient. Escriure dos línies per cada pregunta.

1. Si el temps representa temps de supervivència, què ens diuen aquests gràfics sobre l'impacte de status, diagnosis i loc en la supervivència?
2. Pots identificar algun grup amb un major risc (o menor risc) basant-te en el temps?
3. A partir d'aquests gràfics, quines hipòtesis sobre el temps de supervivència podríem formular?

5.2.3. Anàlisi de la matriu de correlació completa.

Codificació de les variables categòriques

```
In [21]: df_DataBase = pd.read_excel('BrainCancer.xlsx')
df_DataBase.drop(columns = ['Unnamed: 0'], inplace = True)
```

```
In [22]: # Codis
sex_mapping = {'Female': 0, 'Male': 1}
diagnosis_mapping = {'Meningioma': 0, 'HG glioma': 1, 'LG glioma': 2, 'Ot
loc_mapping = {'Supratentorial': 0, 'Infratentorial': 1}
stereo_mapping = {'SRT': 0, 'SRS': 1}

df_mapped = df_DataBase[['sex', 'diagnosis', 'loc', 'stereo']].copy()

df_mapped['sex'] = df_mapped['sex'].map(sex_mapping)
df_mapped['diagnosis'] = df_mapped['diagnosis'].map(diagnosis_mapping)
df_mapped['loc'] = df_mapped['loc'].map(loc_mapping)
df_mapped['stereo'] = df_mapped['stereo'].map(stereo_mapping)

df_DataBase[['sex', 'diagnosis', 'loc', 'stereo']] = df_mapped[['sex', 'diag
print(' Base de dades amb les variables codificades')
df_DataBase
```

Base de dades amb les variables codificades

```
Out [22]:
```

	sex	diagnosis	loc	ki	gtv	stereo	status	time
0	0	0	1	90	6.11	1	0	57.64
1	1	1	0	90	19.35	0	1	8.98
2	0	0	1	70	7.95	1	0	26.46
3	0	2	0	80	7.61	0	1	47.80
4	1	1	0	90	5.06	0	1	6.30
...	...	...	...	...	...	...	...	...
83	1	1	0	80	0.16	0	1	20.69
84	1	1	0	80	19.81	0	1	6.39
85	1	0	0	90	2.50	0	0	32.82
86	1	0	0	90	2.02	1	0	42.07
87	1	3	1	80	0.11	0	0	13.90

88 rows x 8 columns

Exercici avançat

1. Expliqui que fa el mètode "map" Nota: és útil per estalviar línies de programa.


```
In [23]: # Matriu de correlació
correlation_matrix = df_DataBase.corr()
correlation_matrix.round(3)
```

Out [23]:

	sex	diagnosis	loc	ki	gtv	stereo	status	time
sex	1.000	0.204	-0.016	0.078	0.122	-0.168	0.135	-0.033
diagnosis	0.204	1.000	0.307	-0.063	0.117	-0.080	0.155	-0.177
loc	-0.016	0.307	1.000	0.028	-0.036	0.379	-0.201	0.013
ki	0.078	-0.063	0.028	1.000	-0.282	0.016	-0.257	0.255
gtv	0.122	0.117	-0.036	-0.282	1.000	-0.312	0.234	-0.182
stereo	-0.168	-0.080	0.379	0.016	-0.312	1.000	-0.219	0.164
status	0.135	0.155	-0.201	-0.257	0.234	-0.219	1.000	-0.402
time	-0.033	-0.177	0.013	0.255	-0.182	0.164	-0.402	1.000

In [24]:

```
# Heatmap for correlation matrix
plt.figure(figsize=(8, 6))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm')
plt.title('Correlation Heatmap')
plt.show()
```



Exercici 14

Explicació de la matriu de correlació Escriure dos línies per cada pregunta.

1. Identifiqueu les correlacions positives i negatives més fortes (excloent les correlacions d'identitat a la diagonal). Quines són aquestes variables?

2. Trobeu parells de variables amb correlacions properes a zero. Quines són aquestes variables?
3. Pot donar una breu explicació, per exemple sex i loc?

5.2.4. Correlació de les variables amb el temps de supervivència.

Nota: Aquest apartat és important, comparar mes endavant amb els coeficients de regressió lineal.


```
In [25]: print('\n Valors de la correlació de les variables amb el temps de supervivència')
pd.DataFrame(correlation_matrix['time']).round(3).T
```

Valors de la correlació de les variables amb el temps de supervivència.

```
Out [25]:
```

	sex	diagnosis	loc	ki	gtv	stereo	status	time
time	-0.033	-0.177	0.013	0.255	-0.182	0.164	-0.402	1.0

```
In [26]: f, ax = plt.subplots(figsize=(10, 6))
ax = correlation_matrix['time'].iloc[:-1].plot.bar()
plt.title('Correlació temps de supervivència amb altres variables.')
ax.xaxis.grid(True)
ax.yaxis.grid(True)
ax.set(ylabel="Correlatió")
plt.show()
```



Exercici 15

1. Expliqui en un sol paràgraf una explició qualitativa de perquè de la correlació ja sigui positiva o negativa de les variables amb el temps de supervivència.

Regressió no estandard.

- **Nota:** Es fa servir molt sovint, quan s'enten el problema de forma qualitativa i no es vol resoldre el problema de trobar els coeficients amb mínims quadràtics.
(!!!!)

1. De forma qualitativa i amb coeficients pensats a partir de la figura anterior, proposar valors $\beta_0, \beta_1, \beta_2, \dots, \beta_n$ per cada variable per obtenir un estimador qualitatiu del tipus:


$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

Estudiarem amb detall les dos variables **categoriques** amb temps de supervivència negativa i alta.

Variable Descripció de variable

| **diagnosis** | Factor amb nivells "Meningioma", "glioma LG", "glioma HG" i "Altres". |
status | Si el pacient encara està viu al final de l'estudi. 0=Sí, 1=No. | | **time** | Temps de supervivència, en mesos |

```
In [27]: Etiquetes_diagnosis = {0: 'Meningioma', 1: 'HG glioma', 2: 'LG glioma', 3: 'Altres'}
df_DataBase_temp = df_DataBase.copy()
df_DataBase_temp['diagnosis'] = df_DataBase['diagnosis'].map(Etiquetes_diagnosis)
fig, ax = plt.subplots(figsize=(7, 6))
sns.boxplot(df_DataBase_temp, x="diagnosis", y="time", hue="status")
sns.stripplot(df_DataBase_temp, x="diagnosis", y="time", hue="status", size=4)
ax.xaxis.grid(True)
ax.set_ylabel("Time")
sns.despine(trim=True, left=True)
```



Exercici 16

Expliqui un paràgraf,

1. A partir del encavalcament de capces, podeu dir algun comentari sobre si el pacient encara està viu al final de l'estudi. (0=Sí, 1=No). Faci un matíç relacionat amb la dispersió dels punts.

6.0. Predicció amb Regressió lineal.

6.1. Justificació de la partició entre entrenament i test en Machine Learning

En **Machine Learning**, s'ha de dividir el conjunt de dades en **entrenament** i **test**, per tal de poder saber quin serà el rendiment amb dades noves. Justificació:

1. Evitar el sobreajustament:

- Si el model es valida amb les mateixes dades amb què s'ha entrenat, pot aprendre patrons específics (soroll) en lloc de generalitzar. Això afecta la seva capacitat de treballar amb dades noves.

2. Estimació de rendiment general:

- El conjunt de test proporciona una estimació objectiva de com es comportarà el model amb dades reals, **no vistes durant l'entrenament**.

3. Validació del model:

- Permet comparar diferents models o ajustar hiperparàmetres sense comprometre l'avaluació final amb dades conegudes.

4. Evitar biaixos en l'avaluació:

- Sense una partició clara, el model podria obtenir un rendiment inflat artificialment per haver vist les dades de test durant l'entrenament.

Aquesta metodologia assegura un procés de desenvolupament de models robust i aplicable a situacions reals.

Explicació del codi:

1. Definició de les variables X i y:

- Es seleccionen les columnes per a `X` (característiques) exclouent `time`.
- `y` és la variable que volem predir: `time`.

2. Divisió del conjunt de dades:

- S'utilitza `train_test_split` per dividir les dades en conjunts d'entrenament i test.
- `test_size=0.2` : El 20% de les dades es reserva per al test.
- `random_state=42` : Assegura que la divisió sigui reproducible establint una llavor fixa.

3. Verificació de les dimensions:

- Es mostren les dimensions de cada conjunt (`X_train`, `X_test`, `y_train`, `y_test`) per confirmar que la divisió s'ha fet correctament.

```
In [28]: Variables = ["sex", "diagnosis", "loc", "ki", "gtv", "stereo", "status"]
Objectiu = ["time"]
X = df_DataBase[Variables].copy()
y = df_DataBase[Objectiu].copy()
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,

# Mostra les dimensions dels conjunts resultants
print("X_train shape:", X_train.shape) # Dimensions del conjunt d'entren
print("X_test shape:", X_test.shape)   # Dimensions del conjunt de test
print("y_train shape:", y_train.shape) # Dimensions del conjunt d'entren
print("y_test shape:", y_test.shape)   # Dimensions del conjunt de test
```

```
X_train shape: (70, 7)
X_test shape: (18, 7)
y_train shape: (70, 1)
y_test shape: (18, 1)
```

Exercici 17

1. Per aclarir idees, expliqui un parell de línies, perquè es fa la divisió train/test.

6.2. Justificació de l'estandardització en Machine Learning

La estandarització, que consisteix a restar la mitjana i dividir per la desviació típica, és una pràctica important en Machine Learning per les raons següents:

1. Normalització, fer independent de l'escala: (km, cm, kg, gm, etc.)

- Les característiques amb escales diferents poden influir de manera desigual en el model. L'estandardització assegura que totes les característiques tinguin una escala comparable.

2. Evitar biaixos induïts per escales:

- L'ús de característiques amb escales diferents pot introduir biaixos en el rendiment i la interpretació del model.

La estandarització s'aplica utilitzant la següent fórmula:

$$z = \frac{x - \mu}{\sigma}$$

On:

- x és el valor de la variable.
- μ és la mitjana de la variable al conjunt d'entrenament.
- σ és la desviació típica de la variable al conjunt d'entrenament.
- z és el valor estandaritzat.

Nota: És important calcular μ i σ només amb el conjunt d'entrenament, i després utilitzar aquests valors per transformar tant el conjunt d'entrenament com el de test per evitar *data leakage*.

```
In [29]: scaler = StandardScaler()
X_train = X_train.to_numpy()
X_test = X_test.to_numpy()
X_scaled = scaler.fit_transform(X_train)
X_scaled_test = scaler.transform(X_test)
```

```
In [30]: print("Valors abans d'estandaritzar")
pd.DataFrame(X_train, columns = X.columns).describe().round(1).iloc[1:]
```

Valors abans d'estandaritzar

Out [30]:

	sex	diagnosis	loc	ki	gtv	stereo	status
mean	0.5	0.9	0.2	81.0	8.6	0.2	0.4
std	0.5	1.1	0.4	10.9	8.5	0.4	0.5
min	0.0	0.0	0.0	40.0	0.0	0.0	0.0
25%	0.0	0.0	0.0	80.0	2.5	0.0	0.0
50%	0.0	1.0	0.0	80.0	6.6	0.0	0.0
75%	1.0	1.0	0.0	90.0	12.0	0.0	1.0
max	1.0	3.0	1.0	100.0	33.7	1.0	1.0

```
In [31]: print("Valors després d'estandaritzar")
pd.DataFrame(X_scaled, columns = X.columns).describe().round(1).iloc[1:]
```

Valors després d'estandaritzar

Out [31]:

	sex	diagnosis	loc	ki	gtv	stereo	status
mean	0.0	0.0	-0.0	0.0	-0.0	0.0	-0.0
std	1.0	1.0	1.0	1.0	1.0	1.0	1.0
min	-0.9	-0.8	-0.5	-3.8	-1.0	-0.5	-0.8
25%	-0.9	-0.8	-0.5	-0.1	-0.7	-0.5	-0.8
50%	-0.9	0.1	-0.5	-0.1	-0.2	-0.5	-0.8
75%	1.1	0.1	-0.5	0.8	0.4	-0.5	1.2
max	1.1	2.0	2.2	1.8	3.0	2.0	1.2

Exercici 19

1. Per aclarir idees, expliqui un parell de línies, les diferències entre estandaritzar i no estandaritzar en quan a valor mig, desviació estandard, i rang interquantil.

6.3. Calcul de la funció de regressió per estimar el temps de supervivència.

```
In [32]: # Inicialitzem i entrenem el model

model = LinearRegression()
model.fit(X_scaled, y_train)

# Mostrem els coeficients
Variables = ["sex", "diagnosis", "loc", "ki", "gtv", "stereo", "status"]
Objectiu = ["time"]
df_coeficients = pd.DataFrame(model.coef_, columns=Variables)
# Fem prediccions sobre el conjunt de test
y_pred = model.predict(X_scaled_test)
```

6.3.1 Veurem si la predicció és bona.

```
In [33]: import matplotlib.pyplot as plt
import numpy as np
from sklearn.linear_model import LinearRegression

# Assuming y_test and y_pred are already defined
plt.figure(figsize=(10, 6))
plt.scatter(y_test.values.ravel(), y_pred.ravel(), alpha=0.5, color='blue')

plt.xlabel('Temps de supervivència real')
plt.ylabel('Temps de supervivència predict')

# Càlcul del Coeficient de correlació de Pearson
pearson_corr = np.corrcoef(y_test.values.ravel(), y_pred.ravel())[0, 1]

plt.title(f'Scatter Plot de Temps de Supervivència Real vs. Predit\nCoefi')

plt.grid(True)


X = y_test.values
y = y_pred

model = LinearRegression().fit(X, y)
x_range = np.linspace(X.min(), X.max(), 100).reshape(-1, 1)
y_pred_line = model.predict(x_range)

# Línea de regressió
plt.plot(x_range, y_pred_line, color='red', label='Línia de regressió')

plt.legend()

plt.show()
```




Exercici 20

1. Expliqui un parell de línies, la figura anterior, relacioni el coeficient de correlació de Pearson amb la qualitat obtinguda.

6.3.2 Analitzarem els coeficients de predicció lineal,

```
In [34]: ax = df_coeficients.T.plot.bar(legend = False)
plt.title(r'Coeficients de regressió per estimar temps de supervivència.')
ax.xaxis.grid(True)
ax.yaxis.grid(True)
ax.set_ylabel("Coef")
plt.show()
```

Coeficients de regressió per estimar temps de supervivència. $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$



```
In [35]: print('Comparació Coeficients de regressió amab Correlacio')


fig, (ax1, ax2) = plt.subplots(nrows=1, ncols=2, figsize=(15, 5))

df_coeficients.T.plot.bar(ax=ax1, legend=False)
ax1.set_title('Coeficients de regressió.')
ax1.xaxis.grid(True)
ax1.yaxis.grid(True)
ax1.set_ylabel("Coeficients")

correlation_matrix['time'].iloc[:-1].plot.bar(ax=ax2)
ax2.set_title('Correlació amb temps de supervivència .')
ax2.xaxis.grid(True)
ax2.yaxis.grid(True)
ax2.set_ylabel("Correlació")

plt.tight_layout()
plt.show()
```

Comparació Coeficients de regressió amab Correlacio



Exercici 21

1. Expliqui en un paràgraf la semblança entre els coeficients i els valors del predictor lineal. Comenti en coincidència en signe, i coincidència en valors relatius.

6.3.3 Comparació en mes detall

```
In [36]: CompCoef_Corr = pd.concat([df_coeficients.T, correlation_matrix['time']], axis=1)
CompCoef_Corr.columns = ['Coef', 'Corr']
CompCoef_Corr
```

```
Out [36]:
```

	Coef	Corr
sex	0.540031	-0.032950
diagnosis	-3.236392	-0.176827
loc	-0.378801	0.012888
ki	2.816230	0.254931
gtv	-0.650821	-0.181520
stereo	2.886630	0.164199
status	-5.800285	-0.402224

```
In [37]: plt.figure(figsize=(10, 6))
plt.scatter(CompCoef_Corr['Coef'], CompCoef_Corr['Corr'], alpha=0.5, color='blue')

plt.xlabel('Coefficients de regressió')
plt.ylabel('Correlation amb Survival Time')
pearson_corr = np.corrcoef(CompCoef_Corr['Coef'], CompCoef_Corr['Corr'])[0,1]


plt.title(f'Scatter Plot of Coefficients vs. Correlation amb Survival Time')
plt.grid(True)

# Nom de cada variable
for i, txt in enumerate(CompCoef_Corr.index):
    plt.annotate(txt, (CompCoef_Corr['Coef'].iloc[i], CompCoef_Corr['Corr'].iloc[i]))

plt.show()
```

```
print(f'Coeficient de correlació de Pearson: {pearson_corr*100:.2f} % ')
```

Scatter Plot of Coefficients vs. Correlation amb Survival Time.



Coeficient de correlació de Pearson: 94.76 %

Exercici 22

1. Expliqui en un paràgraf com s'interpreta la figura anterior i el significat del coeficient de Pearson, en el sentit de preservar l'ordre.
2. Justifiqui en una línia, a partir de la figura anterior, el us de la regressió no estandard.

Informe Final i Recomanacions

1. Informe on es relaciona la informació obtinguda amb l'estudi fet amb l'EDA amb els resultats obtinguts pel mètode de machine learning.
2. Recomanacions per millorar el sistema i implementar-lo.

Appendix 1

Mètode d'Estimació: Mínims Quadrats (Explicació Detallada)

Per Què Necessitem Mínims Quadrats?

Quan construïm un model de regressió lineal, el nostre objectiu principal és trobar la millor línia que s'ajusta a les nostres dades. "Millor" significa minimitzar la diferència entre els valors predits pel nostre model i els valors reals observats.

La Lògica Darrera els Mínims Quadrats

Imagina que estem dibuixant una línia que passa a través d'un conjunt de punts. La línia mai passarà perfectament per tots els punts. Les diferències entre els punts i la línia s'anomenen "residus" o "errors".

$$e_i = y_i - \hat{y}_i$$

On:

- e_i és l'error per a cada punt
- y_i és el valor real
- $\hat{y}_i$ és el valor predit pel model

Per Què Elevar al Quadrat?

Quan calculem errors, podríem simplement sumar-los. Però hi ha un problema: els errors positius i negatius es cancel·larien entre si. Per exemple:

- Un punt 2 unitats per sobre de la línia
- Un altre punt 2 unitats per sota de la línia

Si sumem aquests errors, obtindríem 0, quan clarament hi ha desviació!

Per resoldre això, elevem els errors al quadrat:

1. Sempre seran positius
2. Els errors grans tindran més pes
3. Penalitza més les prediccions lluny de la línia real

La Fórmula Matemàtica

La funció de cost de mínims quadrats es defineix com:

$$\min_{\beta} \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_n x_{ni}))^2$$

Interpretem cada part:

- $\sum$ significa "suma de tots els punts"
- $(y_i - \text{predicció})^2$ calcula l'error quadràtic de cada punt
- Busquem minimitzar aquesta suma total d'errors

Mètodes de Resolució

Hi ha diverses tècniques per minimitzar aquest error:

1. Solució Analítica:

- Derivades
- Àlgebra lineal
- Fórmula matemàtica tancada

2. Mètodes Iteratius:

- Descens de Gradient
- Optimitza els coeficients pas a pas
- Especialment útil per conjunts de dades grans

Exemple Intuïtiu

Pensem en un agricultors que vol predir la collita:

- Variables: Pluja, temperatura, fertilitzant
- Mínims quadrats trobaran els millors pesos per cada variable
- L'objectiu: minimitzar la diferència entre collites predites i reals

Limitacions

El mètode de mínims quadrats assumeix:

- Relació linear entre variables
- Errors distribuïts normalment
- No hi ha outliers extrems

Conclusió

Mínims quadrats és una eina matemàtica elegant que ens permet construir models predictius ajustant-nos el màxim possible a les dades reals, minimitzant sistemàticament els nostres errors de predicció.