

Pràctica de Regressió Lineal amb regularització amb la base de dades "Mid-Atlantic Wage Data".

Objectius de la pràctica:

1. Treballar amb la base de dades "Mid-Atlantic Wage Data".
 - Suposarem que és un problema que ens han encarregat resoldre i proporcionarem:
 - A. Analitzar les variables i les dependències entre elles, mitjançant una anàlisi exploratòria de les dades (EDA).
 - B. Explicació de com les variables d'entrada permeten explicar el valor del salari i la classe de feina.
 - C. **Predicció de Salaris**: Utilitzar característiques demogràfiques, de salut i laborals per predir salaris o logaritmes de salaris.
2. Estudiarem el problema del **Sobreajustament o Overfitting**, i dos mètodes per resoldre el problema:
 - A. Regressió Ridge: regularització amb norma 2
 - B. Lasso: regularització amb norma 1

1. Descripció del problema i la base de dades:

Explicació de la Base de Dades: Mid-Atlantic Wage Data

La base de dades **Mid-Atlantic Wage Data** va ser creada amb l'objectiu de proporcionar un conjunt de dades per a l'anàlisi estadística i el desenvolupament de models en l'àmbit de l'aprenentatge automàtic i l'economia laboral. Aquesta base de dades recull informació sobre els salaris i altres factors rellevants de 3000 treballadors masculins en la regió del Mid-Atlantic dels Estats Units. Les dades es van recopilar per permetre:

- Estudis sobre la disparitat salarial basada en factors demogràfics com ara edat, raça, i nivell educatiu.
- Anàlisi de com el tipus de feina (industrial vs. informació) afecta els salaris.
- Investigació sobre la relació entre salut, assegurança mèdica, i guanys salarials.

Les dades van ser compilades manualment per Steve Miller d'Inquidia Consulting (anteriorment Open BI), utilitzant el Suplement de Març de 2011 del Current Population Survey (CPS), que és una enquesta mensual realitzada pel Bureau of Labor Statistics dels EUA i el Census Bureau, veure [1] o [2].

La base de dades conté informació com:

- **Demografia:** edat, raça, estat civil.
- **Educació i Treball:** nivell educatiu, tipus de feina.
- **Salut i Beneficis:** estat de salut i cobertura d'assegurança mèdica.
- **Ingressos:** salari brut i log del salari.

Bibliografia

- [1] **James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013).** *An Introduction to Statistical Learning with Applications in R*. Springer.
- [2] **URL:** <https://intro-stat-learning.github.io/ISLP/datasets/Wage.html>

1.1. Variables de la base de dades

Variable	Descripció
year	Any en què es va registrar la informació del salari
age	Edat del treballador
maritl	Estat civil (categories: '1. Never Married', '2. Married', '3. Widowed', '4. Divorced', '5. Separated')
race	Raça (categories: '1. White', '2. Black', '3. Asian', '4. Other')
education	Nivell educatiu (categories: '1. < HS Grad', '2. HS Grad', '3. Some College', '4. College Grad', '5. Advanced Degree')
region	Regió de Mid-Atlantic
jobclass	Tipus de treball (categories: '1. Industrial', '2. Information')
health	Nivell de salut (categories: '1. <=Good', '2. >=Very Good')
health_ins	Estat de l'assegurança de salut (categories: '1. Yes', '2. No')
logwage	Logaritme del salari del treballador
wage	Salari brut del treballador

Exercici 1

1. Per tal de clarificar els objectius d'aquesta pràctica, redactar un paràgraf resumint el tipus de base de dades utilitzada i l'objectiu de la pràctica.
2. Abans d'aplicar mètodes d'Intel·ligència artificial, cal tenir una intuïció sobre com influeixen les variables observacionals el resultat. A partir de la descripció de les variables escriu breument la llista de variables que poden augmentar o disminuir el valor del salari. Igual per la variable tipus de treball. Redactar una explicació d'una línia per justificar cada cas.

1. Sobreajustament o Overfitting

Sobreajustament o **Overfitting** ocorre quan un model d'aprenentatge automàtic no només aprèn els patrons subjacents de les dades d'entrenament, sinó també el soroll o fluctuacions aleatòries. Com a resultat, el model funciona bé amb les dades d'entrenament però no generalitza bé amb noves dades, com les dades de test.

1.1. Per què l'Overfitting és un problema?

L'overfitting és un problema perquè el model "memoritza" les dades d'entrenament, incloent-hi el soroll i les fluctuacions aleatòries. Com a resultat, el model ajusta perfectament les dades d'entrenament, però no pot generalitzar bé a noves dades no vistes, com les dades de test o en situacions del món real.

Això provoca que el model tingui un rendiment pobre en la predicció de dades noves, ja que ha après patrons que no són generals ni útils fora del conjunt d'entrenament. En resum, un model que sofreix d'overfitting no és fiable ni robust per a situacions noves, la qual cosa limita la seva aplicabilitat.

1.1.1. Explicació amb una figura de l'Overfitting

Idea bàsica: massa paràmetres proporcionen massa graus de llibertat, i per tant, el model pot **ajustar-se al soroll** en lloc de captar la dependència funcional.


Per visualitzar l'overfitting, considerem un exemple d'ajustar un model polinòmic a les dades. Suposem un conjunt de dades amb soroll i volem ajustar una corba:

1. Recta $y = ax + b$: **2** graus de llibertat: $P(x) = a_1x + a_0$
2. Polinomi de grau 10: **11** graus de llibertat:

$$P(x) = a_{10}x^{10} + a_9x^9 + a_8x^8 + a_7x^7 + a_6x^6 + a_5x^5 + a_4x^4 + a_3x^3 + a_2x^2 + a_1x + a_0$$

Casos que es poden donar:

1. **Underfitting:** El model és massa senzill i no captura la tendència subjacent. Això passa quan utilitzem un model amb pocs graus de llibertat. El model no detecta els patrons reals de les dades.
 - **Exemple:** Utilitzar una línia recta quan les dades tenen una forma corbada.
2. **Ajust perfecte:** El model ajusta perfectament les dades, modelant tots els patrons (inclòs el soroll).
 - **Exemple:** Un polinomi que segueix la forma funcional que ha creat les dades.
3. **Overfitting:** El model és massa complex i "memoritza" les dades, incloent-hi fluctuacions aleatòries o soroll. Funciona molt bé amb les dades d'entrenament però falla en dades no vistes (dades de test).
 - **Exemple:** Un polinomi de grau molt alt que fa moltes corbes per ajustar-se a cada punt de les dades d'entrenament.



Exercici 2

1. Explicar qualitativament (tres línies) la diferència en quan a aproximació de la funció $y = f(x) = ax + b$ entre la línia blava i la vermella.

```
In [1]: import matplotlib.pyplot as plt
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
from sklearn.pipeline import make_pipeline
np.random.seed(45)
x = np.linspace(0, 10, 50)
y = 2 * x + 1 + np.random.normal(0, 4, size=len(x)) # Afegim soroll
# Ajustem diferents models

# Regressió lineal (Underfitting)
linear_model = LinearRegression()
linear_model.fit(x.reshape(-1, 1), y)


# Regressió polinòmica (Overfitting)
poly_model = make_pipeline(PolynomialFeatures(degree=10), LinearRegression())
poly_model.fit(x.reshape(-1, 1), y)
# Obtenir els coeficients del model polinòmic
# Extraiem els coeficients del segon pas del pipeline (LinearRegression)
poly_coef = poly_model.named_steps['linearregression'].coef_
poly_features = poly_model.named_steps['polynomialfeatures']

# Crear figura amb dos subplots
fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(8, 4))
#fig.suptitle(' \n 1. P(x) = a_1x + a_0$, \n 2. Polinòmic de grau 10', f

# Plot 1: Model Lineal
```

```
# Representació dels coeficients del model lineal
ax1.bar(['Pendent: $a_1$', 'Intersecció: $a_0$'],
        [linear_model.coef_[0], linear_model.intercept_],
        color=['skyblue', 'darkblue'])
ax1.set_title('$P(x) = a_1x + a_0$')
ax1.set_ylabel('Valor del Coeficient')
ax1.grid(True, alpha=0.3)

# Plot 2: Model Polinòmic
# Generem les etiquetes per als termes polinòmics
terms = [f'a_{i}' for i in range(len(poly_coef))]
ax2.bar(terms, poly_coef, color='darkblue')
#ax2.set_title('Coeficients del Model Polinòmic de grau 10')
ax2.set_xlabel('$P(x) = a_{10}x^{10} + a_9x^9 + a_8x^8 + a_7x^7 + a_6x^6$')
ax2.set_ylabel('Valor de $a_i$')
ax2.tick_params(axis='x', rotation=45)
ax2.grid(True, alpha=0.3)
```



Exercici 2

1. Explicar la diferència entre els coeficients dels models. Què pot significar, que en el model complicat, un terme estigui multiplicat per 100 i un altre per -100?, expliqui breument que li passarà a un error de modelatge o al soroll de les dades.
2. Raoniu, en dues línies, per què limitar els valors dels coeficients pot servir per millorar-ne les prestacions.
3. Expliqui en dues línies, per què reduir el nombre de paràmetres redueix la flexibilitat en l'ajustament del model.

2. Regressió Ridge i Lasso: Definicions Formal

2.1. Regressió Ridge

La regressió Ridge és una tècnica de regularització que afegeix un terme **penalització a la funció d'error** de la regressió lineal. El propòsit és prevenir el **sobreajustament (overfitting)** reduint la magnitud dels coeficients. La funció de cost per a la regressió Ridge és:

$$J(\beta) = \frac{1}{2n} \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \alpha \sum_{j=1}^p \beta_j^2$$

On:

- n és el nombre d'observacions.
- p és el nombre de característiques.
- y_i és l'objectiu per a l'observació i .
- x_{ij} són els predictors per la variable j .
- β_0 és el terme independent o intercept.
- β_j són els coeficients dels predictors x_{ij} .
- α és el paràmetre de regularització (hiperparàmetre). Valors més alts d' α resulten en una penalització més gran dels coeficients.

La regularització de Ridge té l'efecte de **reduir tots els coeficients** β_j .

- *Utilitat:* cas en que tots els predictors són importants però necessitem controlar el seu impacte.

2.2. Regressió Lasso

La regressió Lasso (Least Absolute Shrinkage and Selection Operator) també és un mètode de regularització, però utilitza una funció de penalització diferent que pot **reduir alguns coeficients exactament a zero**.

- *Utilitat:* Selecció automàtica de característiques (variable j), es a dir, es determina quins x_{ij} son rellevants per la predicció.
- La funció de cost per a la regressió Lasso és:

$$J(\beta) = \frac{1}{2n} \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \alpha \sum_{j=1}^p |\beta_j|$$

On:

- Les definicions de n , p , y_i , x_{ij} , β_0 , i β_j són les mateixes que per a la regressió Ridge.
- α és el paràmetre de regularització. Com més alt sigui α , més coeficients seran reduïts a zero.

La regularització de Lasso és especialment útil quan es tracta de datasets amb moltes característiques on es vol seleccionar un subconjunt d'elles per simplificar el model.

2.3. Comparació:

- **Ridge**: Redueix tots els coeficients però no els fa arribar a zero. És millor quan es sospita que totes les característiques són rellevants.
- **Lasso**: Pot fer que alguns coeficients siguin zero, efectivament seleccionant característiques. És ideal per a la selecció de característiques i models més interpretables.

2.4. Interpretació del Paràmetre α

- α és controla la flexibilitat d'ajustament en ambdós models:
 - Si α és massa petit, el model es comporta com una regressió lineal sense penalització.
 - Si α és massa gran, el model pot subajustar les dades.

Per determinar el millor valor de α , sovint s'utilitza una cerca per **cross-validation**.

Nota: Mes endavant explicarem el mètode de **cross-validation**.

3. Part pràctica.

- Primer carreguem les llibreries de python
- Després carreguem la base de dades

Carreguem les llibreries

```
In [2]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import mean_squared_error, accuracy_score
```

Lectura de la base de dades.

```
In [3]: file_path = 'Wage.csv'

# Llegim el fitxer CSV i l'emmagatzem al DataFrame
df = pd.read_csv(file_path)
# Veurem una mostra de les dades
df.head()
```

Out [3]:

	year	age	maritl	race	education	region	jobclass	health	health_ins
0	2006	18	1. Never Married	1. White	1. < HS Grad	2. Middle Atlantic	1. Industrial	1. <=Good	2. No
1	2004	24	1. Never Married	1. White	4. College Grad	2. Middle Atlantic	2. Information	2. >=Very Good	2. No
2	2003	45	2. Married	1. White	3. Some College	2. Middle Atlantic	1. Industrial	1. <=Good	1. Yes
3	2003	43	2. Married	3. Asian	4. College Grad	2. Middle Atlantic	2. Information	2. >=Very Good	1. Yes
4	2005	50	4. Divorced	1. White	2. HS Grad	2. Middle Atlantic	2. Information	1. <=Good	1. Yes

Mirem el tipus de dades del DataFrame per si s'han de transformar valors

In [4]: `df.info()`

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3000 entries, 0 to 2999
Data columns (total 11 columns):
#   Column          Non-Null Count  Dtype
---  -
0   year            3000 non-null   int64
1   age             3000 non-null   int64
2   maritl          3000 non-null   object
3   race            3000 non-null   object
4   education       3000 non-null   object
5   region          3000 non-null   object
6   jobclass        3000 non-null   object
7   health          3000 non-null   object
8   health_ins      3000 non-null   object
9   logwage         3000 non-null   float64
10  wage            3000 non-null   float64
dtypes: float64(2), int64(2), object(7)
memory usage: 257.9+ KB
```

In [5]: `object_cols = df.select_dtypes(include=['object']).columns`

```
# iterem en la llista de columnes
for col in object_cols:
    print("_"*40)
    unique_values = df[col].unique()
    print(f"Valors unics per la columna '{col}':")
    print(unique_values)
```

Valors únics per la columna 'maritl':

['1. Never Married' '2. Married' '4. Divorced' '3. Widowed' '5. Separated']

Valors únics per la columna 'race':

['1. White' '3. Asian' '4. Other' '2. Black']

Valors únics per la columna 'education':

['1. < HS Grad' '4. College Grad' '3. Some College' '2. HS Grad' '5. Advanced Degree']

Valors únics per la columna 'region':

['2. Middle Atlantic']

Valors únics per la columna 'jobclass':

['1. Industrial' '2. Information']

Valors únics per la columna 'health':

['1. <=Good' '2. >=Very Good']

Valors únics per la columna 'health_ins':

['2. No' '1. Yes']

Exercici 3

1. Recordatori d'altres pràctiques. En una línia, quin mètode de Pandas es pot utilitzar per transformar categories a valors numèrics?

3.1. Anàlisi exploratòria de dades (EDA)

3.1.1. Entendre l'estructura del DataFrame.

Recordar Metafora: un full excel.

Anàlisi descriptiva de les columnes numèriques

```
In [6]: print(df[['year', 'age', 'logwage', 'wage']].describe().round(3))
```

	year	age	logwage	wage
count	3000.000	3000.000	3000.000	3000.000
mean	2005.791	42.415	4.654	111.704
std	2.026	11.542	0.352	41.729
min	2003.000	18.000	3.000	20.086
25%	2004.000	33.750	4.447	85.384
50%	2006.000	42.000	4.653	104.922
75%	2008.000	51.000	4.857	128.680
max	2009.000	80.000	5.763	318.342

Exercici 4

1. Apartir l'instrucció `df_DataBase.describe()`, comparar la mitjana aritmètica i mediana (percentil 50%) i les desviacions estandard. Expliqueu en una línia si hi ha alguna variable que es devii de la distribució Gausiana. Observar la diferència entre `log salari` i el `salari` sense processar.

Anàlisi descriptiva de les columnes amb categories

In [7]: `df[object_cols].describe()`

Out [7]:

	maritl	race	education	region	jobclass	health	health_ins
count	3000	3000	3000	3000	3000	3000	3000
unique	5	4	5	1	2	2	2
top	2. Married	1. White	2. HS Grad	2. Middle Atlantic	1. Industrial	2. >=Very Good	1. Yes
freq	2074	2480	971	3000	1544	2142	2083

Combinacions de categories que apareixen

In [8]:

```
df_test = df[object_cols]
unique_combinations = df[object_cols].drop_duplicates()
print('_'*40,f'\n Total elements de la base de dades:{df.shape[0]}\n', '
print('_'*40,f'\n Total de combinacions: {unique_combinations.shape[0]}
unique_combinations.index = np.arange(len(unique_combinations))
print(f'Total elements de la base de dades:{df.shape[0]}')
unique_combinations
```

Total elements de la base de dades:3000

Total de combinacions: 316

Total elements de la base de dades:3000

Out [8]:

	maritl	race	education	region	jobclass	health	health_ins
0	1. Never Married	1. White	1. < HS Grad	2. Middle Atlantic	1. Industrial	1. <=Good	2. No
1	1. Never Married	1. White	4. College Grad	2. Middle Atlantic	2. Information	2. >=Very Good	2. No
2	2. Married	1. White	3. Some College	2. Middle Atlantic	1. Industrial	1. <=Good	1. Yes
3	2. Married	3. Asian	4. College Grad	2. Middle Atlantic	2. Information	2. >=Very Good	1. Yes
4	4. Divorced	1. White	2. HS Grad	2. Middle Atlantic	2. Information	1. <=Good	1. Yes
...	...	...	...	...	...	...	...
311	5. Separated	2. Black	3. Some College	2. Middle Atlantic	2. Information	1. <=Good	2. No
312	1. Never Married	1. White	5. Advanced Degree	2. Middle Atlantic	1. Industrial	1. <=Good	2. No
313	1. Never Married	2. Black	3. Some College	2. Middle Atlantic	1. Industrial	2. >=Very Good	2. No
314	1. Never Married	4. Other	3. Some College	2. Middle Atlantic	1. Industrial	1. <=Good	1. Yes
315	2. Married	2. Black	1. < HS Grad	2. Middle Atlantic	2. Information	2. >=Very Good	2. No

316 rows × 7 columns

Exercici 5

1. Comparar la proporció de les combinacions possibles de variables categòriques amb el total d'elements de la base de dades. Quina proporció hi ha? Escriure en una línia, quina variable es podria utilitzar per segmentar els individus per tal de predir el salari?

3.1.2. EDA dels Salaris

El següent codi realitza tres diagrames per entendre la distribució i les relacions entre les variables de la base de dades de salaris:

1. Histograma: Mostra la distribució dels salaris amb una tendència (KDE - Kernel Density Estimate).
2. Diagrama de dispersió (scatter) amb Ajust Polinòmic: Aquest gràfic mostra la relació entre l'edat i el salari, amb una regressió polinòmica de segon grau per capturar possibles tendències no lineals.
3. Correlació entre variables: Correlació entre edat, logaritme del salari i el salari brut. Les cel·les més clares indiquen una correlació positiva forta, mentre que les més fosques indiquen una correlació negativa.


```
In [9]: fig, axes = plt.subplots(1, 3, figsize=(30, 10)) # 1 fila, 3 columnas

# Visualització de la distribució dels salaris
sns.histplot(df['wage'], kde=True, ax=axes[0])
axes[0].set_title('Distribució de Salaris')
axes[0].set_xlabel('Salari')
axes[0].set_ylabel('Frequència')

# Relació entre edat i salari
sns.regplot(x='age', y='wage', data=df, order=2, ax=axes[1], label="Ajust")
axes[1].set_title('Relació entre Edat i Salari')
axes[1].set_xlabel('Edat')
axes[1].set_ylabel('Salari')
axes[1].legend()

# Correlació entre variables numèriques
correlation_matrix = df[['age', 'logwage', 'wage']].corr()
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', ax=axes[2])
axes[2].set_title('Matriu de Correlació')

plt.tight_layout() # Ajusta l' espaiat
plt.show()
```



Exercici 6

Explicació en un paràgraf per cada punt:

1. Què es pot dir de l'histograma del salari?

És gaussià?, amb un pic clar i desviació simètrica? Què pot significar que hi hagi dos pics?

2. Des del punt de vista sociològic, es pot explicar que la dependència del salari amb l'edat sigui quadràtica?

Es pot observar que hi ha dues poblacions?

3. En el diagrama de correlació, es pot explicar per què un dels dos (salari o logSalari) té una dependència més gran amb l'edat?

Quina utilitat pot tenir saber-ho?


```
In [10]: fig, axes = plt.subplots(1, 3, figsize=(15, 5))

# Gràfic 1: Dispersió entre edat i salari segons el tipus de feina
sns.scatterplot(x='age', y='wage', hue='jobclass', data=df, ax=axes[0])
axes[0].set_title('Relació entre edat i salari segons el tipus de feina')
axes[0].set_xlabel('Edat')
axes[0].set_ylabel('Salari')

# Gràfic 2: Boxplot entre nivell educatiu i salari
sns.boxplot(x='education', y='wage', data=df, ax=axes[1])
axes[1].set_title('Relació entre nivell educatiu i salari')
axes[1].set_xlabel('Nivell educatiu')
axes[1].set_ylabel('Salari')
axes[1].tick_params(axis='x', rotation=45) # Rotació de les etiquetes de

# Gràfic 3: Boxplot entre estat civil i salari
sns.boxplot(x='maritl', y='wage', data=df, ax=axes[2])
axes[2].set_title('Relació entre estat civil i salari') # Títol corregit
axes[2].set_xlabel('Estat civil') # Etiqueta eix x corregida
axes[2].set_ylabel('Salari')
axes[2].tick_params(axis='x', rotation=0) # Rotació de les etiquetes de l

plt.tight_layout() # Ajusta el disseny per evitar solapaments
plt.show()
```



Exercici 7

Respondre en un paràgraf per cada punt.

- Diagrama de dispersió:** Existeix tendència entre edat i salari? Hi ha (en promig) alguna diferència entre tenir feines industrial i en informació?
- Educació vs. Salari:** Hi ha alguna tendència en la mediana (percentil 50%)? Té sentit que hi hagin outliers (valors atípics) altament improbables?


3. **Estat civil vs. Salari:** Hi ha alguna tendència en la mediana (percentil 50%)? Té sentit que hi hagin outliers (valors atípics) altament improbables?

```
In [11]: fig, axes = plt.subplots(1, 2, figsize=(15, 6)) #

# Visualització de la distribució dels salaris
sns.histplot(df['wage'], kde=True, ax=axes[0], color='blue')
axes[0].set_title('Distribució de Salaris')
axes[0].set_xlabel('Salari')
axes[0].set_ylabel('Frequència')

# Visualització de la distribució del log salaris
sns.histplot(df['logwage'], kde=True, ax=axes[1], color='green')
axes[1].set_title('Distribució de log Salaris')
axes[1].set_xlabel('log Salari')
axes[1].set_ylabel('Frequència')

plt.tight_layout() # Ajusta l' espaiat
plt.show()
df[['wage', 'logwage']].describe().round(3).T.iloc[:,1:]
```



```
Out[11]:
```

	mean	std	min	25%	50%	75%	max
wage	111.704	41.729	20.086	85.384	104.922	128.680	318.342
logwage	4.654	0.352	3.000	4.447	4.653	4.857	5.763

Exercici 8

Respon en un paràgraf.

- Justifica per què la transformació logarítmica crea una distribució més gaussiana.
 - Nota:** El mètode de regressió lineal assumeix que les variables tenen una distribució gaussiana, amb simetria al voltant del valor mitjà.

3.1.3. Codificació de variables categòriques per a la regressió

- **LabelEncoder** transforma variables categòriques en etiquetes numèriques.
- **Nota:** alternativa a la funció `.map()`, d'altres pràctiques

```
In [12]: le = LabelEncoder()
df['maritl_encoded'] = le.fit_transform(df['maritl'])
df['race_encoded'] = le.fit_transform(df['race'])
df['education_encoded'] = le.fit_transform(df['education'])
df['jobclass_encoded'] = le.fit_transform(df['jobclass'])
df['health_encoded'] = le.fit_transform(df['health'])
df['health_ins_encoded'] = le.fit_transform(df['health_ins'])
encoded_variables = ['maritl_encoded', 'race_encoded', 'education_encoded', 'jobclass_encoded', 'health_encoded', 'health_ins_encoded']
df[encoded_variables].head(10).T
```

```
Out[12]:
```

	0	1	2	3	4	5	6	7	8	9
maritl_encoded	0	0	1	1	3	1	1	0	0	1
race_encoded	0	0	0	2	0	0	3	2	1	0
education_encoded	0	3	2	3	1	3	2	2	2	1
jobclass_encoded	0	1	0	1	1	1	0	1	1	1
health_encoded	0	1	0	1	0	1	1	0	1	1
health_ins_encoded	1	1	0	0	0	0	0	0	0	0

Exercici 9

Respon en un paràgraf.

1. Justificar el procés de passar de variable categòrica a numèrica.

- **Pista:** Pensar en termes de $y = \sum_{j=1}^p \beta_j x_{ij}$

3.1.4. Matriu de correlació per variables numèriques

Recordatori de la definició formal de la Funció de Correlació

El coeficient de correlació entre dues variables X i Y és el coeficient de correlació de Pearson r , que es calcula com:

$$r_{X,Y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

On:

- n és el nombre de parells de puntuacions.
- X_i i Y_i són els punts de mostra individuals indexats amb i .
- $\bar{X}$ i $\bar{Y}$ són les mitjanes de X i Y , respectivament.

Recordatori dels valors de cada variable categòrica:

Variable	Codi Numèric	Descripció
maritl	1	Never Married (Mai Casat)
	2	Married (Casat/Casada)
	3	Widowed (Vidu/Vídua)
	4	Divorced (Divorciat/Divorciada)
	5	Separated (Separat/Separada)
race	1	White (Blanc/Blanca)
	2	Black (Negre/Negra)
	3	Asian (Asiàtic/Asiàtica)
	4	Other (Altres)
education	1	< HS Grad (Sense graduat d'ESO/Batxillerat)
	2	HS Grad (Graduat d'ESO/Batxillerat)
	3	Some College (Alguns estudis universitaris)
	4	College Grad (Graduat universitari)
	5	Advanced Degree (Postgrau/Màster/Doctorat)
health	1	<=Good (<=Bo/Bona)
	2	>=Very Good (>=Molt Bo/Molt Bona)
health_ins	1	Yes (Sí)
	2	No (No)

```
In [13]: # Creem la figura amb 1 fila i 3 columnes
fig, axes = plt.subplots(1, 3, figsize=(15, 6)) # Ajustem figsize segons

# Calculem les matrius de correlació per a cada conjunt de variables
matriu_corr1 = df[['race_encoded', 'maritl_encoded', 'logwage']].corr()
matriu_corr2 = df[['health_encoded', 'education_encoded', 'logwage']].corr()
matriu_corr3 = df[['health_ins_encoded', 'education_encoded', 'logwage']].corr()


# Dibuixem els mapes de calor a cada subplot amb anotacions i mapa de col
sns.heatmap(matriu_corr1, annot=True, cmap='coolwarm', ax=axes[0])
axes[0].set_title(' Raça, Estat Civil, Logaritme del Salari')
axes[0].set_xlabel('') # Eliminem l'etiqueta predeterminada de l'eix x
axes[0].set_ylabel('') # Eliminem l'etiqueta predeterminada de l'eix y

sns.heatmap(matriu_corr2, annot=True, cmap='coolwarm', ax=axes[1])
axes[1].set_title(' Salut, Educació, Logaritme del Salari')
axes[1].set_xlabel('')
axes[1].set_ylabel('')

sns.heatmap(matriu_corr3, annot=True, cmap='coolwarm', ax=axes[2])
axes[2].set_title(' Assegurança Mèdica, Educació, Logaritme del Salari')
axes[2].set_xlabel('')
axes[2].set_ylabel('')

# Ajustem el disseny per evitar que els elements se superposin
```

```
plt.tight_layout()
plt.show()
```



Exercici 10

Respon en un paràgraf.

1. Figura 1: Raça, Estat Civil, Logaritme del Salari

- Quina és la correlació més alta entre aquestes variables?
- Hi ha alguna correlació negativa destacable?
- Com interpreteu el signe de la correlació entre "Raça" i "Logaritme del Salari"? (veure codificació)

2. Figura 2: Salut, Educació, Logaritme del Salari

- Quina variable té la correlació més forta amb el "Logaritme del Salari"?
- Hi ha alguna correlació feble o propera a zero?
- Com interpreteu el signe de la correlació entre "Salut" i "Educació"?

3. Figura 3: Assegurança Mèdica, Educació, Logaritme del Salari

- Com afecta l'"Assegurança Mèdica" el "Logaritme del Salari"?
- La correlació entre "Educació" i "Logaritme del Salari" és positiva o negativa?
- Hi ha algun patró evident en la correlació entre "Assegurança Mèdica" i "Educació"?

3.1.5. Anàlisi de la relació entre la cobertura d'assegurança de salut i les variables d'educació, estat civil i raça.

Recordatori de les categories de cada variable:

Variable	Codi Numèric	Descripció
maritl	1	Never Married (Mai Casat)

Variable	Codi Numèric	Descripció
	2	Married (Casat/Casada)
	3	Widowed (Vidu/Vídua)
	4	Divorced (Divorciat/Divorciada)
	5	Separated (Separat/Separada)
race	1	White (Blanc/Blanca)
	2	Black (Negre/Negra)
	3	Asian (Asiàtic/Asiàtica)
	4	Other (Altres)
education	1	< HS Grad (Sense graduat d'ESO/Batxillerat)
	2	HS Grad (Graduat d'ESO/Batxillerat)
	3	Some College (Alguns estudis universitaris)
	4	College Grad (Graduat universitari)
	5	Advanced Degree (Postgrau/Màster/Doctorat)
region	2	Middle Atlantic (Atlàntic Mitjà)
jobclass	1	Industrial (Industrial)
	2	Information (Informació)
health	1	<=Good (<=Bo/Bona)
	2	>=Very Good (>=Molt Bo/Molt Bona)
health_ins	1	Yes (Sí)
	2	No (No)


```
In [14]: fig, axes = plt.subplots(1, 3, figsize=(30, 10)) # 1 fila, 3 columnes

# Gràfic 1: Educació vs Assegurança de Salut
sns.countplot(x='education', hue='health_ins', data=df, ax=axes[0])
axes[0].set_title('Educació vs Assegurança de Salut')
axes[0].set_xlabel('Nivell d\'Educació')
axes[0].set_ylabel('Nombre de Treballadors')
axes[0].legend(title='Assegurança de Salut')

# Gràfic 2: Estat Civil vs Assegurança de Salut
sns.countplot(x='maritl', hue='health_ins', data=df, ax=axes[1])
axes[1].set_title('Estat Civil vs Assegurança de Salut') # Títol corregit
axes[1].set_xlabel('Estat Civil') # Etiqueta corregida
axes[1].set_ylabel('Nombre de Treballadors')
axes[1].legend(title='Assegurança de Salut')

# Gràfic 3: Raça vs Assegurança de Salut
sns.countplot(x='race', hue='health_ins', data=df, ax=axes[2])
axes[2].set_title('Raça vs Assegurança de Salut') # Títol corregit
axes[2].set_xlabel('Raça') # Etiqueta corregida
axes[2].set_ylabel('Nombre de Treballadors')
axes[2].legend(title='Assegurança de Salut')
```

```
plt.tight_layout() # Ajusta el disseny per evitar solapaments
plt.show()
```



Exercici 10

Respon amb un paràgraf breu cada pregunta.

1. Educació vs. Assegurança de Salut:

- Hi ha una diferència en la proporció de treballadors amb assegurança de salut segons el seu nivell educatiu?
- Es pot observar una tendència clara entre el nivell educatiu i la possessió d'assegurança de salut? (contestar en termes de proporcions)

2. Estat Civil vs. Assegurança de Salut

- L'estat civil dels treballadors influeix en la probabilitat de tenir assegurança de salut? (contestar en termes de proporcions)
- Quin estat civil té la major/menor proporció de treballadors amb assegurança?
- Hi ha diferències significatives en la cobertura d'assegurança entre els diferents estats civils?

3. Raça vs. Assegurança de Salut

- Hi ha disparitats en la cobertura d'assegurança de salut entre els diferents grups racials? (contestar en termes de proporcions)
- Quin grup racial té la major/menor proporció de treballadors amb assegurança?

3.1.5. Anàlisi de la relació entre Tipus de Treball i les variables d'educació, estat civil i raça.

Recordatori de les categories de cada variable:

Variable	Codi Numèric	Descripció
maritl	1	Never Married (Mai Casat)
	2	Married (Casat/Casada)

Variable	Codi Numèric	Descripció
	3	Widowed (Vidu/Vídua)
	4	Divorced (Divorciat/Divorciada)
	5	Separated (Separat/Separada)
race	1	White (Blanc/Blanca)
	2	Black (Negre/Negra)
	3	Asian (Asiàtic/Asiàtica)
	4	Other (Altres)
education	1	< HS Grad (Sense graduat d'ESO/Batxillerat)
	2	HS Grad (Graduat d'ESO/Batxillerat)
	3	Some College (Alguns estudis universitaris)
	4	College Grad (Graduat universitari)
	5	Advanced Degree (Postgrau/Màster/Doctorat)
region	2	Middle Atlantic (Atlàntic Mitjà)
jobclass	1	Industrial (Industrial)
	2	Information (Informació)
health	1	<=Good (<=Bo/Bona)
	2	>=Very Good (>=Molt Bo/Molt Bona)
health_ins	1	Yes (Sí)
	2	No (No)


```
In [15]: fig, axes = plt.subplots(1, 3, figsize=(30, 10)) # 1 fila, 3 columnes

# Gràfic 1: Educació vs Assegurança de Salut
sns.countplot(x='education', hue='jobclass', data=df, ax=axes[0])
axes[0].set_title('Educació vs Assegurança de Salut')
axes[0].set_xlabel('Nivell d'Educació')
axes[0].set_ylabel('Nombre de Treballadors')
axes[0].legend(title='Tipus de Treball')

# Gràfic 2: Estat Civil vs Assegurança de Salut
sns.countplot(x='maritl', hue='jobclass', data=df, ax=axes[1])
axes[1].set_title('Estat Civil vs Assegurança de Salut') # Títol corregit
axes[1].set_xlabel('Estat Civil') # Etiqueta corregida
axes[1].set_ylabel('Nombre de Treballadors')
axes[1].legend(title='Tipus de Treball')

# Gràfic 3: Raça vs Assegurança de Salut
sns.countplot(x='race', hue='jobclass', data=df, ax=axes[2])
axes[2].set_title('Raça vs Assegurança de Salut') # Títol corregit
axes[2].set_xlabel('Raça') # Etiqueta corregida
axes[2].set_ylabel('Nombre de Treballadors')
axes[2].legend(title='Tipus de Treball')
```

```
plt.tight_layout() # Ajusta el disseny per evitar solapaments
plt.show()
```



Exercici 10

1. Educació vs. Tipus de Treball

- Hi ha una distribució diferent dels tipus de treball segons el nivell educatiu?
- Quin nivell educatiu té una major proporció de treballadors en el sector industrial/informació?
- Es pot observar alguna relació entre el nivell educatiu i la probabilitat de treballar en un sector o un altre?

2. Estat Civil vs. Tipus de Treball

- L'estat civil dels treballadors està relacionat amb el tipus de treball que tenen?
- Es predictiva la variable estat civil per predir el tipus de treball?
- Es poden identificar patrons en la distribució dels tipus de treball segons l'estat civil?

3. Raça vs. Tipus de Treball

- Hi ha diferències en la distribució dels tipus de treball entre els diferents grups racials?
- Algun grup racial està sobrerrepresentat o infrarepresentat en algun dels sectors laborals?
- Es predictiva la variable Raça per predir el tipus de treball?

3.2. Predicció amb les tècniques: Regressió i lasso.

Variables: Predicció de Salaris i Tipus de Treball:

3.2.1. Repartim les dades en bases d'entrenament i test i Estandarització de les dades.

- Justificació de repartir les dades en bases d'entrenament i test: Dividim el conjunt de dades en un conjunt d'entrenament (80% de les dades) i un conjunt de prova (20% de les dades) utilitzant `train_test_split`. Això ens permet entrenar

el model amb una part de les dades i provar-ne el rendiment amb una altra part que no ha estat utilitzada per a l'entrenament.

- Justificació de l'estandarització de les dades: Vegeu l'explicació més avall.

```
In [16]: import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.linear_model import LinearRegression, Lasso, Ridge
from sklearn.metrics import mean_squared_error, r2_score

# Carreguem el DataFrame
file_path = 'Wage.csv'
df = pd.read_csv(file_path)
# Codifiquem les variables categòriques
le = LabelEncoder()
categorical_columns = ['maritl', 'race', 'education', 'jobclass', 'health']
for col in categorical_columns:
    df[col + '_encoded'] = le.fit_transform(df[col])

# Seleccióem les característiques i la variable objectiu
features = ['age', 'year'] + [col + '_encoded' for col in categorical_columns]
X = df[features]
y = df['logwage'] # Utilitzem 'logwage' per evitar problemes amb la regressió

# Dividim les dades en conjunt de entrenament i prova
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Normalitzem les dades
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

```
In [17]: print('**Nota**: Existeixen altres maneres de codificar que en alguns casos funcionen millor.')
X.head()
```

****Nota**:** Existeixen altres maneres de codificar que en alguns casos funcionen millor.

```
Out[17]:
```

	age	year	maritl_encoded	race_encoded	education_encoded	jobclass_encoded
0	18	2006	0	0	0	
1	24	2004	0	0	3	
2	45	2003	1	0	2	
3	43	2003	1	2	3	
4	50	2005	3	0	1	

3.2.2. Necessitat d'estandaritzar les variables

Explicació:

La normalització de dades és una tècnica que ajusta les característiques (features) d'un conjunt de dades de manera que tinguin la mateixa escala. Això és especialment útil en models d'aprenentatge automàtic on les característiques tenen diferents rangs o unitats de mesura.

StandardScaler realitza una estandardització, que transforma les dades de manera que tinguin una mitjana de zero i una desviació estàndard de 1. La fórmula per estandarditzar una característica x_i és:

$$z_i = \frac{x_i - \mu}{\sigma}$$

On:

- z_i és la característica estandarditzada.
- x_i és la característica original.
- μ és la mitjana de la característica sobre el conjunt de dades d'entrenament.
- σ és la desviació estàndard de la característica sobre el conjunt de dades d'entrenament.

Detalls de les Comandes:

- `scaler = StandardScaler()` : Crea una instància de `StandardScaler`, que és la classe de scikit-learn que realitza aquesta transformació. Aquesta instància encara no ha estat ajustada als nostres dades.
- `X_train_scaled = scaler.fit_transform(X_train)` :
 - **.fit_transform(X_train)** :
 - **Fit**: Calcula la mitjana (μ) i la desviació estàndard (σ) per cada característica en `X_train`.
 - **Transform**: Utilitza aquests paràmetres per transformar les dades d'entrenament (`X_train`) en les noves característiques estandarditzades (`X_train_scaled`). Cada valor x_i de `X_train` es converteix en z_i segons la fórmula anterior.

Per què ho fem:

- **Evitar Bias**: Característiques amb rangs més amples poden tenir un pes més gran en models com la regressió, si no s'estandarditzen.
- **Millorar el Rendiment**: Alguns algorismes d'aprenentatge, especialment els basats en gradients com les xarxes neuronals, funcionen millor o convergeixen més ràpid quan les dades estan normalitzades.
- **Facilitar la Interpretació**: Amb dades estandarditzades, els coeficients dels models són més comparables entre si.

Aquesta normalització es faria per separat per al conjunt de prova amb `scaler.transform(X_test)` per assegurar-se que utilitzem els mateixos paràmetres d'escala (mitjana i desviació estàndard) calculats amb el conjunt d'entrenament.

```
In [18]: pd.DataFrame(X_train, columns = X.columns).describe().iloc[1:3].round(2)
```

Out [18]:

	age	year	maritl_encoded	race_encoded	education_encoded	jobclass
mean	42.30	2005.77	0.98	0.27	2.03	
std	11.53	2.02	0.81	0.64	1.21	

In [19]: `pd.DataFrame(X_train_scaled, columns = X.columns).describe().iloc[1:3].rou`

Out [19]:

	age	year	maritl_encoded	race_encoded	education_encoded	jobclass_enc
mean	0.0	-0.0	0.0	0.0	-0.0	
std	1.0	1.0	1.0	1.0	1.0	

Exercici 11

Per aclarir idees, explicar en paràgraf per què és necessari fer un procés d'estandarització de les dades $z_i = \frac{x_i - \mu}{\sigma}$. Fer servir en l'explicació les diferències `X_train` i `X_train_scaled` que es presenten més amunt.

3.2.3. Predicció Lineal del logaritme del salari amb Regressió Lineal

Aquí utilitzem una regressió lineal bàsica per predir el logaritme del salari. La normalització és important per mantenir les escales de les característiques uniformes.

```
In [20]: # Regressió Lineal
model = LinearRegression()
model.fit(X_train_scaled, y_train)

# Prediccions
y_pred = model.predict(X_test_scaled)

# Avaluem el model
mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f'Error Mitjà Quadrà (MSE): {mse}')
print(f'Coeficient de Determinació (R²): {r2}')
```

Error Mitjà Quadrà (MSE): 0.06862381162874999
 Coeficient de Determinació (R²): 0.37582487645097684

3.2.3. Explicació dels criteris de qualitat: Error Mitjà Quadrà (MSE)

L'**Error Mitjà Quadrà (MSE)** és una mesura de l'error d'un model que ens informa sobre la qualitat de les prediccions en termes de desviació quadrada mitjana entre les prediccions i els valors reals. La fórmula per calcular el MSE és:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$


On:

- n és el nombre de mostres.
- y_i és el valor real o observat per a l'element i .
- $\hat{y}_i$ és la predicció del model per a l'element i .

Interpretació:

- **Més baix és millor:** Un MSE baix significa que les prediccions del model estan molt properes als valors reals, indicant un bon ajust del model.
- **Indica precisió:** Utilitzem MSE per comparar models, ja que un valor més baix suggereix un millor ajustament al conjunt de dades.

3.2.4. Descripció gràfica del significat del MSE.



Exercici 12

1. Interpreta el significat de cada terme de l'equació de l'Error Quadrà Mitjà (MSE) i explica com es relaciona amb la informació visualitzada a la figura.

L'equació representada a la figura és: $\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

Pistes:

- Pensa en el terme $(y_i - \hat{y}_i)$ i la seva relació amb els punts marcats a la figura.

- Què representa la suma $\sum_{i=1}^n$?
- Com influeix el terme $\frac{1}{n}$ en el valor final del MSE?
- Com es relaciona el valor del MSE amb la dispersió dels punts al voltant de la línia perfecta?

3.2.5. Coeficient de Determinació (R^2)

El **Coeficient de Determinació (R^2)**, també conegut com a R quadrat, mesura la proporció de la variància de la variable dependent que és explicada per les variables independents en el model. La fórmula per calcular R^2 és:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$


On:

- y_i és el valor real o observat per a l'element i .
- $\hat{y}_i$ és la predicció del model per a l'element i .
- $\bar{y}$ és la mitjana dels valors reals de y .

Utilitat:

- **Valor entre 0 i 1:** R^2 pot ser des de 0 fins a 1. Un valor de 1 indica que el model explica tota la variabilitat de les dades dependents, mentre que un valor de 0 indica que el model no explica cap variabilitat més enllà de la que faria una mitjana simple.
- **Interpretació:** Un R^2 alt suggereix que el model té una bona capacitat de predicció, ja que explica una gran part de la variància observada. No obstant això, cal tenir en compte que un alt R^2 no sempre significa un model bo, especialment en presència d'overfitting o amb moltes variables.

3.2.6. Descripció gràfica del significat del Coeficient de Determinació (R^2).



Exercici 13

- Interpreta el significat de cada terme de l'equació del Coeficient de Determinació (R^2) i explica com es relaciona amb la informació visualitzada a la figura.

L'equació representada a la figura és: $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

Pistes:

- Recorda el significat del terme $(y_i - \hat{y}_i)$ del MSE. Com es representa a la figura?
- Què representa el terme $(y_i - \bar{y})$? Com es visualitza a la figura?
- Com influeix la relació entre les dues sumes en el valor final del R^2 ?
- Com es relaciona el valor de R^2 amb la qualitat de l'ajust del model?

3.2.7. Interpretació dels coeficients de la regressió lineal.


* Important

```
In [21]: coef_df = pd.DataFrame({
    'Feature': X.columns,
    'Coefficient': model.coef_
})

# Ordenar els coeficients per magnitud per fer el gràfic més llegible
#coef_df = coef_df.sort_values(by='Coefficient', key=abs, ascending=False)
```

```
# Crear el gràfic de barres
plt.figure(figsize=(10, 6))
sns.barplot(x='Feature', y='Coefficient', data=coef_df)

# Ajustar les etiquetes i títol
plt.title('Coeficients de la Regressió Lineal')
plt.xlabel('Característiques')
plt.ylabel('Coefficient')
plt.xticks(rotation=45, ha='right') # Rotar les etiquetes per visibilitat
plt.grid()
# Mostrar el gràfic
plt.tight_layout()
plt.show()
```



In [22]: `coef_df.round(2).T`

Out[22]:

	0	1	2	3	4	
Feature	age	year	maritl_encoded	race_encoded	education_encoded	jobclass_e
Coefficient	0.06	0.02	0.01	-0.01	0.13	

Exercici 14

Exercici important:

$$\logwage = 0.06 \cdot \text{age} + 0.02 \cdot \text{year} + 0.01 \cdot \text{maritl} - 0.01 \cdot \text{race} + 0.13 \cdot \text{education}$$

1. Redactar en un paràgraf la interpretació de la ponderació que es fa per a cada variable (estandaritzada) per tal de calcular el **logwage**.

- Què vol dir el signe de cada coeficient?
- El fet d'estandaritzar, què implica de cara a interpretar els coeficients?
- Hi ha coeficients redundants o que tenen poca capacitat predictiva?

- Si hagués de fer una recomanació a algú que volgués entendre la dependència entre el salari i les variables, què li podria dir?

3.2.8. Regressió Regularitzada: Lasso

La regressió Lasso (Least Absolute Shrinkage and Selection Operator) afegirà un terme de penalització que pot reduir alguns coeficients a zero, realitzant així una **selecció de característiques** implícita. Elimina:

1. Coeficients que són redundants.
2. Combinacions lineals que poden explicar altres variables. (identificar una combinació lineal exacta que expliqui completament una altra variable i després eliminar-la.)

```
In [23]: # Regressió Lasso
alpha_lasso = 0.05
lasso = Lasso(alpha=alpha_lasso) # 'alpha' és el paràmetre de regularitz
lasso.fit(X_train_scaled, y_train)


# Prediccions
y_pred_lasso = lasso.predict(X_test_scaled)

# Avaluem el model Lasso
mse_lasso = mean_squared_error(y_test, y_pred_lasso)
r2_lasso = r2_score(y_test, y_pred_lasso)

print(f'Error Mitjà Quadràtic (Lasso): {mse_lasso}')
print(f'Coeficient de Determinació (Lasso): {r2_lasso}')
```

Error Mitjà Quadràtic (Lasso): 0.07492296071802665

Coeficient de Determinació (Lasso): 0.3185303008840644



Exercici 15

1. Comparar els diagrames de dispersió i els valors de MSE i R^2 respecte a la regressió lineal clàssica.
- És millor o pitjor, quant a valors numèrics i diferències quant a dispersió?
 - Nota: en el cas ideal, el diagrama de dispersió hauria de ser una recta, sense valors laterals.

3.2.9. Interpretació dels coeficients de la regressió LASSO.


* Important

```
In [24]: # Crear un DataFrame amb els coeficients del model Lasso
coef_df_lasso = pd.DataFrame({
    'Feature': X.columns,
    'Coefficient': lasso.coef_
})

# Ordenar els coeficients per magnitud per fer el gràfic més llegible
#coef_df_lasso = coef_df_lasso.sort_values(by='Coefficient', key=abs, asc

# Crear el gràfic de barres per als coeficients de Lasso
plt.figure(figsize=(12, 6))
sns.barplot(x='Feature', y='Coefficient', data=coef_df_lasso)

# Ajustar les etiquetes i títol
plt.title(f'Coeficients de la Regressió Lasso (alpha={alpha_lasso})')
plt.xlabel('Característiques')
plt.ylabel('Coefficient')
plt.xticks(rotation=45, ha='right') # Rotar les etiquetes per visibilitat
plt.grid()
# Mostrar el gràfic
plt.tight_layout()
plt.show()
```



```
In [25]: coef_df_lasso.round(2).T
```

Out [25]:

	0	1	2	3	4	
Feature	age	year	maritl_encoded	race_encoded	education_encoded	jobclass_er
Coefficient	0.01	0.0	0.0	-0.0	0.1	

Exercici 16

Exercici important:

$$\logwage = 0.01 \cdot \text{age} + 0.1 \cdot \text{education} - 0.06 \cdot \text{health_ins}$$

1. Comparar els coeficients de la regressió LASSO amb la regressió lineal.
 - Què vol dir que hi hagin coeficients exactament iguals a zero.
 - Què vol dir el signe de cada coeficient?
 - El fet d'estandaritzar, què implica de cara a interpretar els coeficients?
 - Si hagués de fer una recomanació a algú que volgués entendre la dependència entre el salari i les variables, què li podria dir?

3.2.8. Regressió Regularitzada: Ridge

La regressió Ridge utilitza una regularització diferent, que redueix els coeficients però no els fa arribar a zero, així que tendirà a mantenir més característiques que Lasso.

```
In [26]: # Regressió Ridge
alpha_ridge = 2000
ridge = Ridge(alpha=alpha_ridge) # 'alpha' és el paràmetre de regularitz
ridge.fit(X_train_scaled, y_train)


# Prediccions
y_pred_ridge = ridge.predict(X_test_scaled)

# Avaluem el model Ridge
mse_ridge = mean_squared_error(y_test, y_pred_ridge)
r2_ridge = r2_score(y_test, y_pred_ridge)

print(f'Error Mitjà Quadràtic (Ridge): {mse_ridge}')
print(f'Coeficient de Determinació (Ridge): {r2_ridge}')
```

Error Mitjà Quadràtic (Ridge): 0.07418689737085184

Coeficient de Determinació (Ridge): 0.32522524276733145



Exercici 17

1. Comparar els diagrames de dispersió i els valors de MSE i R^2 respecte a la regressió lineal clàssica i Lasso
- És millor o pitjor, quant a valors numèrics i diferències quant a dispersió?
 - Nota: en el cas ideal, el diagrama de dispersió hauria de ser una recta, sense valors laterals.

```
In [27]: # Crear un DataFrame amb els coeficients del model Ridge
coef_df_ridge = pd.DataFrame({
    'Feature': X.columns,
    'Coefficient': ridge.coef_
})

plt.figure(figsize=(10, 6))
sns.barplot(x='Feature', y='Coefficient', data=coef_df)


# Ajustar les etiquetes i títol
plt.title('Coeficients de la Regressió Lineal')
plt.xlabel('Característiques')
plt.ylabel('Coefficient')
plt.xticks(rotation=45, ha='right') # Rotar les etiquetes per visibilitat
plt.grid()
# Mostrar el gràfic
plt.tight_layout()
plt.show()

# Ordenar els coeficients per magnitud per fer el gràfic més llegible
#coef_df_ridge = coef_df_ridge.sort_values(by='Coefficient', key=abs, ascending=False)

# Crear el gràfic de barres per als coeficients de Ridge
plt.figure(figsize=(12, 6))
sns.barplot(x='Feature', y='Coefficient', data=coef_df_ridge)

# Ajustar les etiquetes i títol
```

```
plt.title(f'Coeficients de la Regressió Ridge (alpha={alpha_ridge})')
plt.xlabel('Característiques')
plt.ylabel('Coeficient')
plt.xticks(rotation=45, ha='right') # Rotar les etiquetes per visibilitat
plt.grid()
# Mostrar el gràfic
plt.tight_layout()
plt.show()
```



Comparació dels coeficients dels predictors

Variable	Regressió lineal	Regressió lineal ridge
age	0.058	0.036
year	0.024	0.014
marital_encoded	0.01	0.009
race_encoded	-0.012	-0.007
education_encoded	0.133	0.077

Variable	Regressió lineal	Regressió lineal ridge
jobclass_encoded	0.011	0.019
health_encoded	0.035	0.024
health_ins_encoded	-0.088	-0.056
region_encoded	0	0

Exercici 14

Exercici important:

1. Quin és el efecte sobre els coeficients d'aplicar la regressió Ridge en aquest problema?.
2. Quin tipus de un biaix introduirà en la predicció de **logwage**?.
3. Com és compara amb la regressió Lasso?.

3.2.9. Consideracions Ètiques

Exercici 15

Redactar un parell de paràgrafs en relació als següents punts:

1. Com podem identificar si un model de machine learning, especialment un de predicció (com ara un de salaris), desavantatja sistemàticament certs grups demogràfics (per exemple, per raça, gènere, situació marital, edat, etc.)?
2. Com podem visualitzar els biaixos presents en les prediccions d'un model?
3. Quin paper juguen les dades d'entrenament en la introducció i perpetuació de biaixos en els models? Com podem analitzar les dades per detectar possibles biaixos inherents?

Informe Final i Recomanacions

1. Informe on es relaciona la informació obtinguda amb l'estudi fet amb l'EDA amb els resultats obtinguts pel mètode de machine learning.
2. Recomanacions per millorar el sistema i implementar-lo.