

Pràctica de Arbres de decisió i base de dades de "vendes de suc de taronja"

Objectiu de la pràctica:

- 1. Aquest notebook il·lustra com utilitzar la tècnica dels arbres de decisió per determinar la marca que ha comprat el client en funció de les variables que descriuen la compra. **Suposarem que es tracta d'un problema que ens han encarregat resoldre i proporcionarem la següent explicació.**
- 2. Fer servir l'EDA (Exploratory Data Analysis) per entendre la base de dades i el problema a resoldre.
- 3. Aprendre a utilitzar els arbres de decisió.
- 4. Aprendre a interpretar els arbres de decisió.
- 5. Estudiar les dependències de la variable de compra ("purchase") en funció de les altres variables.
- 6. Trobar regles senzilles que expliquin el comportament dels clients i les relacions entre les variables.

1. Descripció del problema

1.1. Base de dades

La base de dades conté informació detallada sobre 1.070 compres de suc de taronja de les marques Citrus Hill i Minute Maid, realitzades per diferents clients en diverses botigues durant un període determinat. Per a cada compra, s'enregistra la marca escollida, la setmana de compra, la botiga específica, els preus originals i amb descompte de cada marca, així com la presència de promocions especials. A més, es quantifica la fidelitat dels clients a cada marca i es calcula la diferència de preu de venda entre les dues opcions. Aquesta informació permet analitzar factors com l'impacte dels preus, les promocions i la fidelitat dels clients en la decisió de compra dels consumidors.

1.2. Descripció de les variables de la base de dades de vendes de suc de taronja

Variable	Descripció
Purchase	Un factor que indica si el client va comprar suc de taronja de Citrus Hill (CH) o Minute Maid (MM).
WeekofPurchase	La setmana de la compra.
StoreID	L'ID de la botiga on es va fer la compra.
PriceCH	El preu cobrat pel suc de taronja de Citrus Hill.

Variable	Descripció
PriceMM	El preu cobrat pel suc de taronja de Minute Maid.
DiscCH	El descompte ofert pel suc de taronja de Citrus Hill.
DiscMM	El descompte ofert pel suc de taronja de Minute Maid.
SpecialCH	Indicador de si hi havia una promoció especial pel suc de taronja de Citrus Hill.
SpecialMM	Indicador de si hi havia una promoció especial pel suc de taronja de Minute Maid.
LoyalCH	Fidelitat del client a la marca Citrus Hill.
SalePriceMM	Preu de venda del suc de taronja de Minute Maid.
SalePriceCH	Preu de venda del suc de taronja de Citrus Hill.
PriceDiff	La diferència de preu de venda entre Minute Maid i Citrus Hill.
Store7	Indicador de si la venda es va fer a la botiga 7.
PctDiscMM	Percentatge de descompte pel suc de taronja de Minute Maid.
PctDiscCH	Percentatge de descompte pel suc de taronja de Citrus Hill.
ListPriceDiff	La diferència de preu de llista entre Minute Maid i Citrus Hill.
STORE	Identificador de quina de les cinc botigues es tracta.

Bibliografia

- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning: With Applications in Python*. Springer Nature.
- Stine, R. A., Foster, D. P., & Waterman, R. P. (1998). *Business Analysis Using Regression*.

Exercici 1

1. Per tal de clarificar els objectius d'aquesta pràctica, redactar un paràgraf resumint el tipus de base de dades utilitzada i l'objectiu de la pràctica.
2. Abans d'aplicar mètodes d'Intel·ligència artificial, cal tenir una intuïció sobre com influencien les variables observacionals el resultat. A partir de la descripció de les variables escriu breument la llista de variables que poden augmentar o disminuir la probabilitat de compra. Redactar una explicació d'una línia per justificar cada cas.

2. Arbres de Decisió: Una Introducció Intuïtiva

2.1. Què són els arbres de decisió?

Els arbres de decisió són un mètode d'aprenentatge automàtic que **infereix regles a partir de dades**. Es tracta d'un model predictiu que utilitza una estructura en forma d'arbre per prendre decisions a partir de diferents condicions. Cada **node** de l'arbre representa una pregunta sobre un atribut de les dades, i cada **branca** correspon a una resposta possible a aquesta pregunta. El procés continua fins que s'arriba a un **fulla** de l'arbre, on es pren una decisió final o es fa una predicció.

Metàfora: Seqüències "if then else" que determinen regles per decidir.

2.1.1. Exemple Sencill: Regles per decidir si viatjar o romandre a casa


Imaginarem un arbre de decisió per decidir si val la pena **viatjar** o **romandre a casa** en funció de tres variables:

- **Ventós:** 0 (no ventós), 1 (ventós)
- **Temperatura:** 0 (baix), 1 (alt)
- **Clima:** 0 (dolent), 1 (bo)
-

Un exemple de la base de dades:

	Viatjar	Romandre a casa	Viatjar	Romandre a casa	Viatjar	Viatjar	Viatjar	Romandre a casa
Clima	0	1	0	0	1	0	1	0
Temperatura	1	0	1	0	1	0	0	1
Ventós	0	1	1	0	0	0	1	0

2.1.2. L'estructura de l'arbre després del procés d'inferència:



- Una representació de les regles del arbre anterior:

Ventós	Temperatura	Clima	Decisió
<= 0.50	<= 0.50	<= 0.50	Viatjar
<= 0.50	<= 0.50	> 0.50	Viatjar

Ventós	Temperatura	Clima	Decisió
≤ 0.50	> 0.50	≤ 0.50	Romandre a casa
≤ 0.50	> 0.50	> 0.50	Romandre a casa
> 0.50	≤ 0.50		Romandre a casa
> 0.50	> 0.50		Viatjar

2.1.3. Explicació: Interpretació de l'arbre de decisió

1. Primer node (Ventós):

- Si $\text{Ventós} \leq 0.50$ (no fa vent), es passa a revisar la temperatura.
- Si $\text{Ventós} > 0.50$ (fa vent), es revisa el clima:
 - Si $\text{Clima} \leq 0.50$ (ennuolat), la decisió és **Romandre a casa**.
 - Si $\text{Clima} > 0.50$ (assolellat), la decisió és **Viatjar**.

2. Segon node (Temperatura):

- Si $\text{Temperatura} \leq 0.50$ (no fa calor), es revisa el clima:
 - Si $\text{Clima} \leq 0.50$ (ennuolat), la decisió és **Viatjar**.
 - Si $\text{Clima} > 0.50$ (assolellat), la decisió és també **Viatjar**.
- Si $\text{Temperatura} > 0.50$ (fa calor), independentment del clima, la decisió és **Romandre a casa**.

Aquest arbre és un exemple senzill de com els arbres de decisió poden utilitzar dades categòriques o numèriques per predir una classe. Cada camí des de l'arrel fins a una fulla representa una seqüència de decisions que porten a una predicció. Aquesta estructura fa que els arbres de decisió siguin intuïtius i fàcils d'interpretar.

Bibliografia

- Breiman, L., Friedman, J., Stone, C. J., & Olshen, R. A. (1984). *Classification and Regression Trees*. Chapman and Hall/CRC.
- Duda, R. O., Hart, P. E., & Stork, D. G. (2001). *Pattern Classification* (2nd ed.). John Wiley & Sons.

Exercici 2

1. Per tal de clarificar el concepte, redactar un paràgraf explicant que és un arbre de decisió.

3. Part pràctica.

- Primer carreguem les llibreries de python
- Després carreguem la base de dades

3.1.1 Carreguem les llibreries que farem servir.

```
In [1]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix
import matplotlib.pyplot as plt
```

3.1.2 Carreguem la base de dades de un fitxer tipus 'comma separated values' a un DataFrame de Pandas.

```
In [2]: df_DataBase = pd.read_csv('OJ.csv')
df_DataBase.head()
```

```
Out[2]:
```

	Purchase	WeekofPurchase	StoreID	PriceCH	PriceMM	DiscCH	DiscMM	Spec
0	CH	237	1	1.75	1.99	0.00	0.0	
1	CH	239	1	1.75	1.99	0.00	0.3	
2	CH	245	1	1.86	2.09	0.17	0.0	
3	MM	227	1	1.69	1.69	0.00	0.0	
4	CH	228	7	1.69	1.69	0.00	0.0	

3.1.3. Transformació de les variables qualitatives a numèriques

```
In [3]: df_DataBase['Store7'] = df_DataBase['Store7'].map({'Yes': 1, 'No': 0})
df_DataBase['Purchase'] = df_DataBase['Purchase'].map({'CH': 1, 'MM': 0})
df_DataBase.head()
```

```
Out[3]:
```

	Purchase	WeekofPurchase	StoreID	PriceCH	PriceMM	DiscCH	DiscMM	Spec
0	1	237	1	1.75	1.99	0.00	0.0	
1	1	239	1	1.75	1.99	0.00	0.3	
2	1	245	1	1.86	2.09	0.17	0.0	
3	0	227	1	1.69	1.69	0.00	0.0	
4	1	228	7	1.69	1.69	0.00	0.0	

3.2. Tipus de dades de la base de dades, correcció a float.

```
In [4]: df_DataBase.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1070 entries, 0 to 1069
Data columns (total 18 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Purchase               1070 non-null   int64
1   WeekofPurchase         1070 non-null   int64
2   StoreID                1070 non-null   int64
3   PriceCH                1070 non-null   float64
4   PriceMM                1070 non-null   float64
5   DiscCH                 1070 non-null   float64
6   DiscMM                 1070 non-null   float64
7   SpecialCH              1070 non-null   int64
8   SpecialMM              1070 non-null   int64
9   LoyalCH                1070 non-null   float64
10  SalePriceMM             1070 non-null   float64
11  SalePriceCH             1070 non-null   float64
12  PriceDiff               1070 non-null   float64
13  Store7                  1070 non-null   int64
14  PctDiscMM               1070 non-null   float64
15  PctDiscCH               1070 non-null   float64
16  ListPriceDiff           1070 non-null   float64
17  STORE                   1070 non-null   int64
dtypes: float64(11), int64(7)
memory usage: 150.6 KB
```

Correcció dels tipus de dades.

```
In [5]: df_DataBase = df_DataBase.astype(float)
df_DataBase.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1070 entries, 0 to 1069
Data columns (total 18 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Purchase               1070 non-null   float64
1   WeekofPurchase         1070 non-null   float64
2   StoreID                1070 non-null   float64
3   PriceCH                1070 non-null   float64
4   PriceMM                1070 non-null   float64
5   DiscCH                 1070 non-null   float64
6   DiscMM                 1070 non-null   float64
7   SpecialCH              1070 non-null   float64
8   SpecialMM              1070 non-null   float64
9   LoyalCH                1070 non-null   float64
10  SalePriceMM             1070 non-null   float64
11  SalePriceCH             1070 non-null   float64
12  PriceDiff               1070 non-null   float64
13  Store7                  1070 non-null   float64
14  PctDiscMM               1070 non-null   float64
15  PctDiscCH               1070 non-null   float64
16  ListPriceDiff           1070 non-null   float64
17  STORE                   1070 non-null   float64
dtypes: float64(18)
memory usage: 150.6 KB
```

Exercici 3

1. Expliqui en una línia que fa el mètode `.astype(float)` sobre el DataFrame.

3.3. Anàlisi exploratòria de dades (EDA)

L'anàlisi exploratòria de dades (EDA) permet entendre les característiques d'una base de dades. A través de visualitzacions i estadístiques descriptives, s'identifiquen patrons, anomalies i relacions entre les variables.

3.3.1 Estadístics descriptius.

In [6]: `df_DataBase.describe().round(2).T`

Out [6]:

	count	mean	std	min	25%	50%	75%	max
Purchase	1070.0	0.61	0.49	0.00	0.00	1.00	1.00	1.00
WeekofPurchase	1070.0	254.38	15.56	227.00	240.00	257.00	268.00	278.00
StoreID	1070.0	3.96	2.31	1.00	2.00	3.00	7.00	7.00
PriceCH	1070.0	1.87	0.10	1.69	1.79	1.86	1.99	2.09
PriceMM	1070.0	2.09	0.13	1.69	1.99	2.09	2.18	2.29
DiscCH	1070.0	0.05	0.12	0.00	0.00	0.00	0.00	0.50
DiscMM	1070.0	0.12	0.21	0.00	0.00	0.00	0.23	0.80
SpecialCH	1070.0	0.15	0.35	0.00	0.00	0.00	0.00	1.00
SpecialMM	1070.0	0.16	0.37	0.00	0.00	0.00	0.00	1.00
LoyalCH	1070.0	0.57	0.31	0.00	0.33	0.60	0.85	1.00
SalePriceMM	1070.0	1.96	0.25	1.19	1.69	2.09	2.13	2.29
SalePriceCH	1070.0	1.82	0.14	1.39	1.75	1.86	1.89	2.09
PriceDiff	1070.0	0.15	0.27	-0.67	0.00	0.23	0.32	0.64
Store7	1070.0	0.33	0.47	0.00	0.00	0.00	1.00	1.00
PctDiscMM	1070.0	0.06	0.10	0.00	0.00	0.00	0.11	0.40
PctDiscCH	1070.0	0.03	0.06	0.00	0.00	0.00	0.00	0.25
ListPriceDiff	1070.0	0.22	0.11	0.00	0.14	0.24	0.30	0.44
STORE	1070.0	1.63	1.43	0.00	0.00	2.00	3.00	4.00

Exercici 4

1. Detecti si hi han variables on la el percentil 50% sigui diferent de la mitjana, i la desviació estandard molt diferent del interval interquantil (25%-75%).

3.1.1 Diagrama en capces (Box Plot).

In [7]: `df_DataBase['Purchase']`

```
Out[7]: 0      1.0
        1      1.0
        2      1.0
        3      0.0
        4      1.0
        ...
       1065     1.0
       1066     1.0
       1067     0.0
       1068     1.0
       1069     1.0
        Name: Purchase, Length: 1070, dtype: float64
```


```
In [8]: # Definir les variables a representar (excloent les variables binàries)
variables = df_DataBase.columns
non_binary_vars = [var for var in variables if df_DataBase[var].nunique()

# Crear una figura amb 2 files i 7 columnes
fig, axes = plt.subplots(2, 7, figsize=(20, 10))

# Aplanar l'array d'eixos per facilitar la iteració
axes = axes.flatten()

# Representar cada variable no binària
for i, var in enumerate(non_binary_vars):
    sns.boxplot(y=df_DataBase[var], x=df_DataBase['Purchase'], ax=axes[i])
    axes[i].set_title(var)

# Ajustar
plt.tight_layout()
plt.show()
```



Exercici 5

Una de les avantatges dels arbres de decisió és que poden treballar amb dades no gaussianes, amb valors extrems (outliers) i amb unitats diferents (kg,gm, anys,

segons, etc), pel fet que compara valors.


1. En un paràgraf, expliqui de forma general la distribució de les variables: asimetria, marges dinàmics molt diferents, presència de outliers, etc.
2. Detecti si hi han variables que siguin molt predictives de compra (Purchase)
3. Per aprendre Python.
 - 2.1 Expliqui breument què fa la instrucció: `[var for var in variables if df_DataBase[var].nunique() > 2]`
 - 2.2 Expliqui breument què fa la instrucció: `enumerate(non_binary_vars)`

- Recordatori de les variables:

- | Variable | Descripció |
|-----------------------|---|
| Purchase | Un factor que indica si el client va comprar suc de taronja de Citrus Hill (CH) o Minute Maid (MM). |
| WeekofPurchase | La setmana de la compra. |
| StoreID | L'ID de la botiga on es va fer la compra. |
| PriceCH | El preu cobrat pel suc de taronja de Citrus Hill. |
| PriceMM | El preu cobrat pel suc de taronja de Minute Maid. |
| DiscCH | El descompte ofert pel suc de taronja de Citrus Hill. |
| DiscMM | El descompte ofert pel suc de taronja de Minute Maid. |
| SpecialCH | Indicador de si hi havia una promoció especial pel suc de taronja de Citrus Hill. |
| SpecialMM | Indicador de si hi havia una promoció especial pel suc de taronja de Minute Maid. |
| LoyalCH | Fidelitat del client a la marca Citrus Hill. |
| SalePriceMM | Preu de venda del suc de taronja de Minute Maid. |
| SalePriceCH | Preu de venda del suc de taronja de Citrus Hill. |
| PriceDiff | La diferència de preu de venda entre Minute Maid i Citrus Hill. |
| Store7 | Indicador de si la venda es va fer a la botiga 7. |
| PctDiscMM | Percentatge de descompte pel suc de taronja de Minute Maid. |
| PctDiscCH | Percentatge de descompte pel suc de taronja de Citrus Hill. |
| ListPriceDiff | La diferència de preu de llista entre Minute Maid i Citrus Hill. |
| STORE | Identificador de quina de les cinc botigues es tracta. |

Probabilitat de compra.

```
In [9]: plt.figure(figsize=(5, 3))
sns.countplot(x='Purchase', data=df_DataBase)
plt.title('Distribution of Purchases')
plt.show()
print(f'Valor promig de probabilitat de compra: {df_DataBase.Purchase.mea
```



Valor promig de probabilitat de compra: 61.03 %

Exercici 6

1. Escrigui en una línia el codi d'un programa classificador de compra amb un encert del 61%.

Comparació d'histogrames de variables seleccionades factoritzant per compra


```
In [10]: fig, axes = plt.subplots(1, 3, figsize=(20, 5))

# Plot for 'PriceDiff'
sns.histplot(data=df_DataBase, x='PriceDiff', hue='Purchase', kde=True, ax=axes[0].set_title('Price Difference Distribution'))

# Plot for 'LoyalCH'
sns.histplot(data=df_DataBase, x='LoyalCH', hue='Purchase', kde=True, ax=axes[1].set_title('Loyalty Channel Distribution'))

# Plot for 'DiscMM'
sns.histplot(data=df_DataBase, x='DiscMM', hue='Purchase', kde=True, ax=axes[2].set_title('Discount Method Distribution'))

plt.tight_layout()
plt.show()
```



Exercici 7

1. Analitzi els histogrames anteriors, i per cada variable indiqueu els marges en que la venda es mes possible i en una linea doni una explicació.


```
In [11]: fig, axes = plt.subplots(1, 3, figsize=(20, 5))

# Scatter plot for PriceDiff vs LoyalCH
sns.scatterplot(x='PriceDiff', y='LoyalCH', hue='Purchase', data=df_DataBase)
axes[0].set_title('Impact of CH Discounts on Sale Price')

# Scatter plot for PriceDiff vs DiscMM
sns.scatterplot(x='PriceDiff', y='DiscMM', hue='Purchase', data=df_DataBase)
axes[1].set_title('Impact of MM Discounts on Sale Price')

# Scatter plot for LoyalCH vs DiscMM
sns.scatterplot(x='LoyalCH', y='DiscMM', hue='Purchase', data=df_DataBase)
axes[2].set_title('Interaction Between CH and MM Discounts')

# Adjust layout and display the plot
plt.tight_layout()
plt.show()
```



Exercici 8

1. Analitzi els diagrames de dispersions anteriors, i per cada combinació de variables indiqueu si hi ha una dependència en les combinacions i la probabilitat de venda i en una linea doni una explicació.

Distribució de preus per Citrus Hill i Minute Maid

Recordar la codificació: `df_DataBase['Purchase'].map({'CH': 1, 'MM': 0})`


- Anàlisi de la sensibilitat al preu.

```
In [12]: fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(18, 6)) # Create a figure

# KDE plot for Citrus Hill and Minute Maid prices
sns.histplot(ax=ax1, data=df_DataBase[df_DataBase['Purchase'] == 1]['PriceDiff'])
sns.histplot(ax=ax1, data=df_DataBase[df_DataBase['Purchase'] == 0]['PriceDiff'])
ax1.set_title('Distribució de preus per Citrus Hill i Minute Maid')
ax1.set_xlabel('Preu')
ax1.legend()

# Countplot for purchase distribution
sns.countplot(ax=ax2, x='Purchase', data=df_DataBase)
ax2.set_title('Distribució de Compres de Suc de Taronja')
```

```
plt.tight_layout() # Adjust spacing between subplots
plt.show()
```



Exercici 9

1. En base a l'histograma anterior, expliqui en una línia quina marca té més possibilitats de vendre's.
2. Quina utilitat pot tenir la instrucció: `kde=True`

La KDE, o "Kernel Density Estimation".

- La KDE és una tècnica estadística que ens ajuda a visualitzar la distribució de dades contínues de manera suau i contínua. En lloc d'utilitzar un histograma, que crea barres per representar la freqüència de dades dins d'interval·ls específics, la KDE crea una corba suau que estima la densitat de probabilitat en diferents punts al llarg de l'interval de dades.

Eficàcia dels Descomptes

Com afecten els descomptes a les vendes de cada marca. Aquests gràfics mostren com els descomptes afecten el preu de venda final per a cada marca.


```
In [13]: import seaborn as sns
import matplotlib.pyplot as plt

# Crear una figura amb dos subgràfics en una fila
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 6))

# Primer gràfic de dispersió: Impacte dels descomptes de CH
sns.scatterplot(ax=ax1, x='PctDiscCH', y='SalePriceCH', hue='Purchase', d
ax1.set_title('Impacte dels Descomptes de CH en el Preu de Venta')
ax1.set_xlabel('Percentatge de Descompte CH')
ax1.set_ylabel('Preu de Venta CH')

# Segon gràfic de dispersió: Impacte dels descomptes de MM
sns.scatterplot(ax=ax2, x='PctDiscMM', y='SalePriceMM', hue='Purchase', d
ax2.set_title('Impacte dels Descomptes de MM en el Preu de Venta')
ax2.set_xlabel('Percentatge de Descompte MM')
ax2.set_ylabel('Preu de Venta MM')

plt.tight_layout()
plt.show()
```



Exercici 10

1. En base al diagrama de dispersió anterior, expliqui en dos línies si els descomptes són efectius per augmentar les vendes en cada marca.

4.0 Resultats amb arbres de decisió.

4.1 Per què un arbre de decisió és una bona solució

Raons:

1. **Interpretabilitat:** L'estructura de l'arbre permet visualitzar el procés de presa de decisions a cada nivell, fent clar com el model arriba a les seves prediccions.
2. **Gestió de Diferents Tipus de Dades:** Els arbres de decisió poden tractar tant dades numèriques com categòriques sense necessitat de preprocessament:
 - A. estandarització.
 - B. Convertir variables categòriques en numèriques.
3. **Robustesa a l'Escala:** Els arbres de decisió no són sensibles a l'escala de les variables, al fer comparacions, no depen de l'escala/unitats de les variables.
 - A. La comparació $Pes > 1\text{kg}$, es tracta igual que $Pes > 1000\text{ grms}$.
 - B. A diferència d'alguns altres algorismes, com la regressió lineal, els arbres de decisió no requereixen normalització o estandarització.
4. **Relacions No Lineals:** Els arbres de decisió poden capturar relacions no lineals entre les característiques i la variable objectiu. Això és útil per a conjunts de dades complexos on la relació entre variables no és estrictament lineal.

Comparació amb Regressió i K-means

- **Regressió:**

- **Regressió Lineal:** Assumeix una relació lineal entre les característiques i la variable objectiu. Requereix escalatge de característiques i pot no funcionar bé si la relació és no lineal.
- **Arbre de Decisió:** Pot capturar relacions no lineals i no requereix escalatge de característiques. És més flexible en la gestió de conjunts de dades complexos.
- **K-means Clustering:**
 - **K-means:** Un algorisme de clustering utilitzat per a l'aprenentatge no supervisat. Agrupa punts de dades en clústers basats en la seva similitud. És sensible a l'escalatge de variables i requereix escalatge de característiques.
 - **Arbre de Decisió:** Un algorisme d'aprenentatge supervisat utilitzat per a tasques de classificació i regressió. Prediu directament la variable objectiu i és robust a l'escalatge de variables.

Exercici 11

1. Per aclarir idees, resumeixi en un paràgraf els avantatges dels arbres de decisió enfront d'altres mètodes.

4.2 Partició de la base en train i test

```
In [14]: features = ['WeekofPurchase', 'StoreID', 'PriceCH', 'PriceMM', 'DiscCH',
target = 'Purchase'

X_train, X_test, y_train, y_test = train_test_split(df_DataBase[features]
```

Exercici 13

1. En dos línies, expliqui perquè es fa la partició en train i test.
2. **Quina propietat** tenen els arbres que fa que no sigui necessari fer una estandarització de les dades?

4.3 Estimació del arbre.

- Inicialitzar i entrenar el classificador d'arbre de decisió

```
In [15]: clf = DecisionTreeClassifier(random_state=42)
clf.fit(X_train, y_train)
```

```
Out[15]: ▼ DecisionTreeClassifier ⓘ ⓘ
DecisionTreeClassifier(random_state=42)
```

4.3. Recordatori: Avaluació del Model

Paràmetres d'Avaluació de la qualitat del model

1. Precisió (Precision)

Definició: La precisió és la relació entre les instàncies predites correctament i el total d'instàncies en el conjunt de dades. Mesura l'efectivitat general del model.

$$\text{Precisió} = \frac{VP + VN}{VP + VN + FP + FN}$$

On:

- VP = Veritables Positius
- VN = Veritables Negatius
- FP = Falsos Positius
- FN = Falsos Negatius

2. Sensibilitat (Recall)

Definició: La sensibilitat, també coneguda com a recall, és la relació entre les observacions positives predites correctament i tots els positius reals. Mesura la capacitat del model per identificar instàncies positives.

$$\text{Sensibilitat} = \frac{VP}{VP + FN}$$

On:

- VP = Veritables Positius
- FN = Falsos Negatius

3. Puntuació F1 (F1-Score)

Definició: La puntuació F1 és la mitjana harmònica de l'exactitud i la sensibilitat. Proporciona un equilibri entre les dues mètriques, especialment en conjunts de dades desequilibrats.

$$\text{Puntuació F1} = 2 \times \frac{\text{Exactitud} \times \text{Sensibilitat}}{\text{Exactitud} + \text{Sensibilitat}}$$

4. Suport (Support):

Definició: El suport és el nombre d'ocurrències de cada classe en el conjunt de dades de test. Reflecteix la quantitat de dades disponibles per a cada classe per avaluar el rendiment del model.

$$\text{Suport} = TP + FN$$

On:

- **TP:** Nombre d'instàncies que són de la classe i han estat correctament predites com a tals.
- **FN:** Nombre d'instàncies de la classe que han estat incorrectament predites com a no pertanyents a la classe.

4.4 Predicció sobre la base de test i prestacions.

```
In [16]: y_pred = clf.predict(X_test)

# Avaluar el model
accuracy = accuracy_score(y_test, y_pred)
report = classification_report(y_test, y_pred, output_dict=True)
df_report = pd.DataFrame(report).transpose()

# Optionally, if you want to reset the index to make 'precision', 'recall'
df_report = df_report.reset_index()
df_report = df_report.rename(columns={'index': 'class'})
print(f'Precisió: {accuracy*100:2.2f} %')
print('\n \n Informe de Classificació:')
df_report.set_index('class', inplace = True)

df_report.iloc[:2].round(2)
```

Precisió: 71.64 %

Informe de Classificació:

```
Out[16]:
```

	precision	recall	f1-score	support
class				
0.0	0.66	0.63	0.64	109.0
1.0	0.75	0.77	0.76	159.0

Exercici 14


1. En base a les definicions anteriors donar una explicació en un paràgraf del informe de classificació. Valori les prestacions del classificador.

Recordatori: Matriu de confusió

Definició: Una matriu de confusió és una taula que s'utilitza per avaluar el rendiment d'un model de classificació. Resumeix el recompte de prediccions de veritables positius, veritables negatius, falsos positius i falsos negatius.

	Predicció Positiva	Predicció Negativa
Real Positiu	VP	FN
Real Negatiu	FP	VN

```
In [17]: # Matriu de confusió
conf_matrix = confusion_matrix(y_test, y_pred)
plt.figure(figsize=(6, 4))
sns.heatmap(conf_matrix, annot=True, fmt='d', cmap='Blues', xticklabels=[
plt.xlabel('Prediccions')
plt.ylabel('Valors Reals')
plt.title('Matriu de Confusió')
plt.show()
```




Exercici 15

1. En base a les definicions anteriors donar una explicació en un paràgraf de la Matriu de Confusió. Valori les prestacions del classificador.

4.5 Representació del arbre de decisió.

```
In [18]: from sklearn.tree import plot_tree

plt.figure(figsize=(20,10))
plot_tree(clf, filled=True, rounded=True, feature_names=features, class_
plt.show())
```



```
In [19]: from sklearn.tree import export_text

tree_rules = export_text(clf, feature_names=features)
print(tree_rules)
```

```

|--- LoyalCH <= 0.50
|   |--- LoyalCH <= 0.28
|       |--- LoyalCH <= 0.06
|           |--- WeekofPurchase <= 268.50
|               |--- class: 0.0
|           |--- WeekofPurchase > 268.50
|               |--- PriceDiff <= 0.29
|                   |--- class: 0.0
|               |--- PriceDiff > 0.29
|                   |--- class: 1.0
|       |--- LoyalCH > 0.06
|           |--- LoyalCH <= 0.21
|               |--- WeekofPurchase <= 273.00
|                   |--- WeekofPurchase <= 261.00
|                       |--- PriceDiff <= -0.13
|                           |--- SalePriceMM <= 1.64
|                               |--- WeekofPurchase <= 236.50
|                                   |--- WeekofPurchase <= 234.00
|                                       |--- LoyalCH <= 0.16
|                                           |--- class: 0.0
|                                               |--- LoyalCH > 0.16
|                                                   |--- truncated branch of depth
2
|               |--- WeekofPurchase > 234.00
|                   |--- class: 1.0
|               |--- WeekofPurchase > 236.50
|                   |--- class: 0.0
|               |--- SalePriceMM > 1.64
|                   |--- class: 1.0
|               |--- PriceDiff > -0.13
|                   |--- LoyalCH <= 0.06
|                       |--- class: 1.0
|                   |--- LoyalCH > 0.06
|                       |--- SalePriceMM <= 2.26
|                           |--- WeekofPurchase <= 228.00
|                               |--- class: 1.0
|                           |--- WeekofPurchase > 228.00
|                               |--- WeekofPurchase <= 237.50
|                                   |--- class: 0.0
|                               |--- WeekofPurchase > 237.50
|                                   |--- truncated branch of depth
7
|               |--- SalePriceMM > 2.26
|                   |--- class: 1.0
|               |--- WeekofPurchase > 261.00
|                   |--- PriceMM <= 2.04
|                       |--- class: 0.0
|                   |--- PriceMM > 2.04
|                       |--- class: 1.0
|               |--- WeekofPurchase > 273.00
|                   |--- class: 0.0
|       |--- LoyalCH > 0.21
|           |--- StoreID <= 1.50
|               |--- SalePriceCH <= 1.78
|                   |--- class: 1.0
|               |--- SalePriceCH > 1.78
|                   |--- class: 0.0
|           |--- StoreID > 1.50
|               |--- WeekofPurchase <= 229.50
|                   |--- STORE <= 1.00

```

```

|--- class: 1.0
|--- STORE > 1.00
|--- class: 0.0
|--- WeekofPurchase > 229.50
|--- ListPriceDiff <= 0.31
|--- class: 0.0
|--- ListPriceDiff > 0.31
|--- WeekofPurchase <= 272.50
|--- class: 0.0
|--- WeekofPurchase > 272.50
|--- class: 1.0
|--- LoyalCH > 0.28
|--- PriceDiff <= 0.05
|--- SpecialCH <= 0.50
|--- SalePriceMM <= 1.74
|--- LoyalCH <= 0.28
|--- class: 1.0
|--- LoyalCH > 0.28
|--- StoreID <= 3.50
|--- ListPriceDiff <= 0.23
|--- class: 0.0
|--- ListPriceDiff > 0.23
|--- LoyalCH <= 0.47
|--- class: 0.0
|--- LoyalCH > 0.47
|--- STORE <= 1.50
|--- class: 0.0
|--- STORE > 1.50
|--- class: 1.0
|--- StoreID > 3.50
|--- PriceCH <= 1.72
|--- class: 1.0
|--- PriceCH > 1.72
|--- WeekofPurchase <= 276.50
|--- class: 0.0
|--- WeekofPurchase > 276.50
|--- class: 1.0
|--- SalePriceMM > 1.74
|--- StoreID <= 2.50
|--- class: 1.0
|--- StoreID > 2.50
|--- WeekofPurchase <= 229.50
|--- StoreID <= 3.50
|--- LoyalCH <= 0.44
|--- class: 1.0
|--- LoyalCH > 0.44
|--- class: 0.0
|--- StoreID > 3.50
|--- LoyalCH <= 0.44
|--- class: 0.0
|--- LoyalCH > 0.44
|--- LoyalCH <= 0.49
|--- class: 1.0
|--- LoyalCH > 0.49
|--- class: 0.0
|--- WeekofPurchase > 229.50
|--- class: 0.0
|--- SpecialCH > 0.50
|--- LoyalCH <= 0.37
|--- class: 0.0

```

```

|----- LoyalCH > 0.37
|----- LoyalCH <= 0.47
|----- Store7 <= 0.50
|----- class: 1.0
|----- Store7 > 0.50
|----- LoyalCH <= 0.39
|----- class: 1.0
|----- LoyalCH > 0.39
|----- class: 0.0
|----- LoyalCH > 0.47
|----- PctDiscMM <= 0.20
|----- class: 0.0
|----- PctDiscMM > 0.20
|----- WeekofPurchase <= 233.50
|----- class: 1.0
|----- WeekofPurchase > 233.50
|----- class: 0.0
|---- PriceDiff > 0.05
|---- SpecialCH <= 0.50
|---- LoyalCH <= 0.45
|---- PriceMM <= 2.04
|---- WeekofPurchase <= 234.00
|---- class: 1.0
|---- WeekofPurchase > 234.00
|---- class: 0.0
|---- PriceMM > 2.04
|---- SalePriceMM <= 2.21
|---- LoyalCH <= 0.41
|---- LoyalCH <= 0.31
|---- class: 1.0
|---- LoyalCH > 0.31
|---- WeekofPurchase <= 245.00
|---- WeekofPurchase <= 236.00
|---- class: 1.0
|---- WeekofPurchase > 236.00
|---- class: 0.0
|---- WeekofPurchase > 245.00
|---- STORE <= 1.50
|---- truncated branch of depth
6
|---- STORE > 1.50
|---- truncated branch of depth
5
|---- LoyalCH > 0.41
|---- StoreID <= 1.50
|---- DiscCH <= 0.12
|---- class: 1.0
|---- DiscCH > 0.12
|---- class: 0.0
|---- StoreID > 1.50
|---- class: 0.0
|---- SalePriceMM > 2.21
|---- WeekofPurchase <= 242.50
|---- class: 1.0
|---- WeekofPurchase > 242.50
|---- LoyalCH <= 0.38
|---- class: 0.0
|---- LoyalCH > 0.38
|---- WeekofPurchase <= 254.50
|---- class: 0.0

```

```

|--- WeekofPurchase > 254.50
|--- class: 1.0
---- LoyalCH > 0.45
|--- WeekofPurchase <= 253.50
|--- ListPriceDiff <= 0.23
|--- WeekofPurchase <= 248.50
|--- class: 0.0
|--- WeekofPurchase > 248.50
|--- DiscCH <= 0.05
|--- class: 1.0
|--- DiscCH > 0.05
|--- class: 0.0
|--- ListPriceDiff > 0.23
|--- SalePriceMM <= 2.16
|--- WeekofPurchase <= 235.50
|--- StoreID <= 2.00
|--- class: 0.0
|--- StoreID > 2.00
|--- LoyalCH <= 0.48
|--- class: 0.0
|--- LoyalCH > 0.48
|--- class: 1.0
|--- WeekofPurchase > 235.50
|--- WeekofPurchase <= 252.00
|--- class: 1.0
|--- WeekofPurchase > 252.00
|--- LoyalCH <= 0.48
|--- class: 0.0
|--- LoyalCH > 0.48
|--- class: 1.0
|--- SalePriceMM > 2.16
|--- LoyalCH <= 0.49
|--- class: 1.0
|--- LoyalCH > 0.49
|--- STORE <= 3.50
|--- WeekofPurchase <= 244.00
|--- class: 0.0
|--- WeekofPurchase > 244.00
|--- truncated branch of depth
2
|--- STORE > 3.50
|--- class: 0.0
---- WeekofPurchase > 253.50
|--- LoyalCH <= 0.48
|--- LoyalCH <= 0.48
|--- class: 1.0
|--- LoyalCH > 0.48
|--- class: 0.0
|--- LoyalCH > 0.48
|--- class: 1.0
---- SpecialCH > 0.50
|--- WeekofPurchase <= 271.50
|--- class: 1.0
|--- WeekofPurchase > 271.50
|--- LoyalCH <= 0.41
|--- class: 1.0
|--- LoyalCH > 0.41
|--- LoyalCH <= 0.46
|--- class: 0.0
|--- LoyalCH > 0.46

```

```
| | | | | |--- class: 1.0  
|--- LoyalCH > 0.50  
|   |--- PriceDiff <= -0.39  
|     |--- LoyalCH <= 0.76  
|       |--- StoreID <= 1.50  
|         |--- LoyalCH <= 0.63  
|           |--- class: 0.0  
|             |--- LoyalCH > 0.63  
|               |--- LoyalCH <= 0.71  
|                 |--- class: 1.0  
|                   |--- LoyalCH > 0.71  
|                     |--- class: 0.0  
|       |--- StoreID > 1.50  
|         |--- class: 0.0  
|   |--- LoyalCH > 0.76  
|     |--- LoyalCH <= 0.99  
|       |--- class: 1.0  
|     |--- LoyalCH > 0.99  
|       |--- LoyalCH <= 1.00  
|         |--- class: 0.0  
|       |--- LoyalCH > 1.00  
|         |--- class: 1.0  
|--- PriceDiff > -0.39  
|   |--- PriceMM <= 1.74  
|     |--- LoyalCH <= 0.71  
|       |--- class: 0.0  
|     |--- LoyalCH > 0.71  
|       |--- LoyalCH <= 0.77  
|         |--- StoreID <= 4.50  
|           |--- class: 1.0  
|         |--- StoreID > 4.50  
|           |--- class: 0.0  
|       |--- LoyalCH > 0.77  
|         |--- class: 1.0  
|   |--- PriceMM > 1.74  
|     |--- LoyalCH <= 0.71  
|       |--- PriceDiff <= 0.09  
|         |--- ListPriceDiff <= 0.23  
|           |--- PriceDiff <= -0.25  
|             |--- WeekofPurchase <= 272.50  
|               |--- class: 1.0  
|             |--- WeekofPurchase > 272.50  
|               |--- class: 0.0  
|           |--- PriceDiff > -0.25  
|             |--- LoyalCH <= 0.63  
|               |--- SalePriceMM <= 1.84  
|                 |--- class: 0.0  
|               |--- SalePriceMM > 1.84  
|                 |--- LoyalCH <= 0.56  
|                   |--- class: 0.0  
|                   |--- LoyalCH > 0.56  
|                     |--- SalePriceCH <= 1.96  
|                       |--- class: 1.0  
|                       |--- SalePriceCH > 1.96  
|                         |--- class: 0.0  
|             |--- LoyalCH > 0.63  
|               |--- DiscMM <= 0.25  
|                 |--- class: 1.0  
|               |--- DiscMM > 0.25  
|                 |--- LoyalCH <= 0.69
```

4

```

|---- LoyalCH > 0.69
|---- class: 0.0
|---- LoyalCH > 0.71
|---- WeekofPurchase <= 257.50
|---- WeekofPurchase <= 237.50
|---- class: 1.0
|---- WeekofPurchase > 237.50
|---- LoyalCH <= 0.92
|---- SpecialCH <= 0.50
|---- LoyalCH <= 0.80
|---- STORE <= 0.50
|---- LoyalCH <= 0.76
|---- truncated branch of depth 2
|---- LoyalCH > 0.76
|---- class: 1.0
|---- STORE > 0.50
|---- LoyalCH <= 0.79
|---- class: 1.0
|---- LoyalCH > 0.79
|---- truncated branch of depth 2
|---- LoyalCH > 0.80
|---- class: 1.0
|---- SpecialCH > 0.50
|---- class: 0.0
|---- LoyalCH > 0.92
|---- LoyalCH <= 0.96
|---- StoreID <= 2.50
|---- PriceCH <= 1.81
|---- class: 0.0
|---- PriceCH > 1.81
|---- class: 1.0
|---- StoreID > 2.50
|---- class: 0.0
|---- LoyalCH > 0.96
|---- class: 1.0
|---- WeekofPurchase > 257.50
|---- StoreID <= 2.50
|---- LoyalCH <= 0.98
|---- ListPriceDiff <= 0.13
|---- LoyalCH <= 0.79
|---- class: 0.0
|---- LoyalCH > 0.79
|---- class: 1.0
|---- ListPriceDiff > 0.13
|---- class: 1.0
|---- LoyalCH > 0.98
|---- PriceDiff <= 0.22
|---- class: 1.0
|---- PriceDiff > 0.22
|---- class: 0.0
|---- StoreID > 2.50
|---- STORE <= 3.50
|---- class: 1.0
|---- STORE > 3.50
|---- WeekofPurchase <= 265.50
|---- WeekofPurchase <= 264.50
|---- class: 1.0
|---- WeekofPurchase > 264.50

```

[illegible]

Exercici 16



1. Faci un crítica al arbre estimat?

Pista: Recordar Overfitting i regularització. **Metàfora:** Look up table

4.5.1 Explicació dels paràmetres que controlen l'estructura d'un arbre de decisió.

Paràmetres que determinen l'estructura:

- **max_depth:** És la profunditat màxima de l'arbre. Defineix quantes decisions (nivells) pot arribar a tenir l'arbre abans de fer una predicció. Un valor més alt permetrà estructurar l'arbre amb més detall però pot portar a sobreajustament (overfitting).
- **min_samples_split:** És el nombre mínim d'exemples necessaris per dividir un node intern. Si el nombre d'exemples en un node és menor o igual a aquest valor, no es farà cap nova divisió d'aquest node. Un valor més alt pot prevenir el sobreajustament, ja que forceja a tenir nodes més grans abans de dividir-se.
- **min_samples_leaf:** És el nombre mínim d'exemples que ha de tenir cada fulla (node terminal). Si després d'una divisió, qualsevol fulla resultant té menys exemples que aquest valor, la divisió no es realitzarà. Això ajuda a controlar la complexitat de l'arbre i pot reduir l'efecte de sobreajustament.
- ****Exemples per dos combinacions de paràmetres**
 1. {'max_depth': 2, 'min_samples_split': 2, 'min_samples_leaf': 1},
 2. {'max_depth': 5, 'min_samples_split': 10, 'min_samples_leaf': 10}




4.5 Necessitat de Validació creuada.

4.5.1 Definició

La validació creuada, o cross-validation en anglès, és una tècnica estadística utilitzada en l'aprenentatge automàtic per avaluar com de bé un model generalitza a un conjunt de dades independents.

1. Consisteix a dividir el conjunt de dades d'entrenament en diverses parts, o folds, normalment entre 5 i 10 (Veure figura mes abaix).



2. Un dels folds es reserva com a conjunt de prova, mentre que la resta es fan servir per entrenar el model. Aquest procés es repeteix tantes vegades com folds hi hagi, de manera que cada part del conjunt de dades actua com a conjunt de prova una vegada.

3. Utilitat de la validació:

- A. Detecta el sobreajustament (overfitting), i.e. quan un model s'adapta massa als detalls específics de l'entrenament i no funciona bé amb nous exemples.
- B. Mitjançant la validació creuada, es pot **ajustar millor els paràmetres del model** per aconseguir un equilibri entre l'ajust als dades d'entrenament i la capacitat de generalització.
- C. Permet fer models més robustos i fiables, augmentant la confiança en les prediccions fetes per aquests models en situacions reals.

Cerca en graella (GridSearchCV) per explorar diferents paràmetres de l'arbre de decisió i seleccionar el millor model basat en la precisió.

1. Creació d'un objecte **GridSearchCV**: Aquest és un mètode de selecció de models de scikit-learn que permet fer una cerca exhaustiva sobre paràmetres específics per un estimador (en aquest cas, dt, que és un classificador d'arbre de decisió).

2. Paràmetres de la cerca exhaustiva:

- `estimator=dt`: Especifica el model que es vol optimitzar, aquí és el classificador d'arbre de decisió (dt).

- `param_grid=param_grid`: Defineix la graella de paràmetres sobre la qual es farà la cerca. `param_grid` és un diccionari on les claus són els noms dels paràmetres del model i els valors són llistes de possibles valors per aquests paràmetres.
 - `cv=5`: Estableix la validació creuada amb 5 plecs (folds). Això significa que les dades d'entrenament es dividiran en 5 parts, i el model serà entrenat i validat 5 vegades, amb una part diferent usada com a conjunt de prova cada vegada. Això ajuda a obtenir una estimació més robusta del rendiment del model.
 - `scoring='accuracy'`: Especifica que el criteri per avaluar els models serà l'accuràcia (precisió). Això vol dir que el model que obtingui la major precisió en la validació creuada serà considerat el millor.
3. **GridSearchCV**: fa una cerca exhaustiva per trobar la millor combinació de paràmetres per a un classificador d'arbre de decisió, utilitzant validació creuada per assegurar-se que el model no només s'ajusta bé als dades d'entrenament sinó que també generalitza bé a noves dades.

4.5.2 Creem la partició de validació

```
In [20]: df_DataBase = pd.read_csv('OJ.csv')
df_DataBase['Store7'] = df_DataBase['Store7'].map({'Yes': 1, 'No': 0})
df_DataBase['Purchase'] = df_DataBase['Purchase'].map({'CH': 1, 'MM': 0})

X_train, X_temp, y_train, y_temp = train_test_split(df_DataBase[features]

# Definir la graella de paràmetres
param_grid = {
    'max_depth': [2, 3, 4],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [ 5, 10, 20]
}

# Inicialitzar el classificador d'arbre de decisió
dt = DecisionTreeClassifier(random_state=42)

# Configurar GridSearchCV amb una validació creuada de 5 plecs
grid_search = GridSearchCV(estimator=dt, param_grid=param_grid,
                           cv=5, n_jobs=-1, scoring='accuracy')

# Ajustar la cerca de graella als dades
grid_search.fit(X_train, y_train)

# Millors paràmetres
print("Millors paràmetres:", grid_search.best_params_)

# Millor puntuació de validació creuada
print(f"\n \n Millor precisió de validació creuada: {grid_search.best_sco

# Utilitzar el millor model per fer prediccions en el conjunt temporal pe
best_model = grid_search.best_estimator_
y_pred = best_model.predict(X_temp)

# Matriu de confusió
conf_matrix = confusion_matrix(y_temp, y_pred)
```

```
plt.figure(figsize=(8, 6))
sns.heatmap(conf_matrix, annot=True, fmt='d', cmap='Blues', xticklabels=[
plt.xlabel('Prediccions')
plt.ylabel('Valors Reals')
plt.title('Matriu de Confusió')
plt.show()

# Calcular la precisió en el conjunt temporal
accuracy = accuracy_score(y_temp, y_pred)
print(f'\n \n Precisió en base de test: {accuracy*100:2.2f} %')


report = classification_report(y_temp, y_pred, output_dict=True)
df_report = pd.DataFrame(report).transpose()

# Optionally, if you want to reset the index to make 'precision', 'recall
df_report = df_report.reset_index()
df_report = df_report.rename(columns={'index': 'class'})
print('\n \n Informe de Classificació:')
df_report.set_index('class', inplace = True)

df_report.iloc[:2].round(2)
```

Millors paràmetres: {'max_depth': 4, 'min_samples_leaf': 10, 'min_samples_split': 2}

Millor precisió de validació creuada: 82.39 %



Precisió en base de test: 77.10 %

Informe de Classificació:

Out[20]: precision recall f1-score support

class				
0	0.66	0.81	0.73	162.0
1	0.87	0.74	0.80	266.0


Exercici 17

1. Per aclarir idees, expliqui el que fa el codi anterior en un parell de paràgrafs.
2. Per què les precisions del grid search i la de test són diferents?
3. Què pot dir sobre el Informe de Classificació després de fer la cerca exhaustiva?
4. Què pot dir de la nova matriu de confusió en termes de falsos positius i falsos negatius.

4.6 Abre de decisió estimat amb validació creuada

```
In [21]: from sklearn.tree import plot_tree

plt.figure(figsize=(20,10))
plot_tree(best_model, filled=True, rounded=True, feature_names=features,
plt.show())
```



Exercici 18

1. Interpreti l'arbre anterior. Hi ha alguna variable que sembli més important que d'altres? Hi ha alguna correlació entre les variables de decisió i el tipus de marca

(CH, MM)? Pot proporcionar una jerarquia d'importància de les variables?

Informe Final i Recomanacions

1. Informe on es relaciona la informació obtinguda amb l'estudi fet amb l'EDA amb els resultats obtinguts pel mètode de machine learning.
2. Recomanacions per millorar el sistema i implementar-lo.