

Pràctica de Regressió Logística amb la base de dades "South African Heart Disease Data".

Objectius de la pràctica:

1. Treballar amb la base de dades South African Heart Disease Data.
 - Suposarem que és un problema que ens han encarregat resoldre i proporcionarem:
 - A. Propietats de les variables observades i com es relacionen amb el la presència de malaltia coronària.
 - B. Explicació de com les variables observades afecten la presència de malaltia coronària.
 - C. Crearem un indicador probabilístic de la presència de malaltia coronària.
2. Aprendre a interpretar la geometria de la regressió logística.

1. Descripció del problema:

Objectiu Proporcionar un indicador probabilístic de la presència de malaltia coronària, i una explicació de la importància dels factors que afecten.

Descripció de la base de dades "South African Heart Disease Data".

Un estudi retrospectiu es va dur a terme entre homes d'una regió de risc alt de malalties cardíques al Cap Occidental, Sud-àfrica. Es van incloure aproximadament dos controls per cada cas de malaltia coronària (CHD). Molts dels homes amb CHD havien rebut tractaments per reduir la pressió arterial i altres programes per disminuir els factors de risc després d'haver patit un episodi de CHD, i en alguns casos, les mesures es van prendre després d'aquests tractaments.

Aquestes dades provenen de l'estudi original (amb algunes modificacions com convertir la variable chd en un factor) i estan basades en el paquet ElemStatLearn de 2015, ara arxivat.

A finals dels anys 70, es va observar una alta incidència de malaltia isquèmica cardíaca entre homes blancs, afrikaans-parlants, al sud-oest del Cap (Wyndham, 1982). L'any 1979, Rossouw et al. (1983) van reclutar uns 8.200 habitants (3.357 homes blancs i 3.831 dones blanques) de tres comunitats afrikaner mitjançant una campanya intensiva per correu. Es va determinar la presència o absència de CHD per a cada participant (inicialment com a "1" per als casos i "0" per als controls; actualment com a "Yes" o "No"), juntament amb diversos factors de risc coneguts.

L'objectiu era analitzar la prevalença i intensitat dels factors de risc de CHD en aquestes comunitats, amb especial atenció als factors de risc majors que es podrien

considerar reversibles, com la hipercolesterolèmia, la hipertensió i el tabaquisme (Rossouw et al., 1983).

Hastie i Tibshirani (1987) van seleccionar un subgrup de 465 homes dels 3.357 inicials. Aquest grup incloïa 162 casos de CHD i 303 controls. Tot i això, les dades utilitzades actualment contenen informació sobre 462 subjectes (160 casos i 302 controls), probablement per discrepàncies en els registres. Aquestes dades també es van utilitzar en treballs posteriors de Hastie, Tibshirani i Friedman (2009).

Bibliografia

1. Hastie, T., & Tibshirani, R. (1987). Non-parametric logistic and proportional odds regression. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 36(3), 260-276.
2. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*, 2nd Edition. Springer New York. doi:10.1007/978-0-387-84858-7
3. Rossouw, J. E., Plessis, J. P. D., Benad'e, A. J. S., Jordaan, P. C. J., Kotz'e, J. P., Jooste, P. L., & Ferreira, J. J. (1983). Coronary risk factor screening in three rural communities: The CORIS baseline study. *South African Medical Journal*, 64, 430-436.
4. Wyndham, C. (1982). Trends with time of cardiovascular mortality rates in the populations of the RSA for the period 1968-1977. *South African Medical Journal*, 61, 987-993.

1.1. Variables de la base de dades

La base de dades té de 462 registres i 10 variables.

Característica	Descripció
bp	Pressió sanguínia sistòlica
tobacco	Tabac acumulat (kg)
ldl	Nivell de colesterol LDL (lipoproteïna de baixa densitat)
adiposity	Sobrepès sever (vector numèric)
famhist	Historial familiar de malalties del cor
typea	Comportament tipus A
obesity	Acumulació excessiva de greix (vector numèric)
alcohol	Consum actual d'alcohol
age	Edat a l'inici
chd	Resposta, malaltia coronària del cor

1.2. Explicació de les variables

a) Pressió Sanguínia Sistòlica (sbp)

La pressió sanguínia sistòlica alta és un factor de risc important per a les malalties cardíaques. Un valor elevat de pressió sistòlica pot causar danys als vasos sanguinis, augmentant les probabilitats de formació de placa, arteriosclerosi, i per tant, augmentant el risc de malalties coronàries i atacs de cor.

b) Nivell de Colesterol LDL (Idl)

El colesterol LDL, conegut com el "colesterol dolent", quan està elevat, contribueix a la formació de placa a les artèries. Aquesta placa pot reduir el flux sanguini cap al cor, augmentant el risc d'infart de miocardi o altres malalties coronàries.

c) Historial Familiar (famhist)

Un historial familiar de malalties cardíaques (famhist) indica que hi ha una predisposició genètica. Si hi ha antecedents de malalties cardíaques en la família, especialment en pares o germans, això augmenta el risc personal d'experimentar malalties similars, ja que poden heretar-se factors genètics que afavoreixen aquestes condicions.

d) Comportament de Tipus A

El comportament de tipus A, denotat com **typea** en el conjunt de dades, es refereix a un patró de comportament que es considera un factor de risc per a la malaltia coronària. Aquest comportament està caracteritzat per:

- Ambició intensa
- Impaciència
- Competitivitat
- Tendència a la hostilitat
- Pressió per aconseguir moltes coses en poc temps

Les persones amb aquest tipus de comportament poden experimentar més estrès, el qual està lligat a un major risc de malalties cardíaques.

Definició de Malaltia Cardíaca Coronària (CHD)

La **Malaltia Cardíaca Coronària** (CHD) és una condició en què es redueix o bloqueja el flux sanguini als músculs del cor, generalment a causa de l'acumulació de placa a les artèries coronàries. Això pot portar a angina de pit, infarts de miocardi o fins i tot mort sobtada. Els símptomes poden incloure dolor o malestar al pit, dificultat per respirar, i en casos greus, col·lapse cardíac.

Exercici 1

1. Per tal de clarificar els objectius d'aquesta pràctica, redactar un paràgraf resumint el tipus de base de dades utilitzada i l'objectiu de la pràctica.
2. Abans d'aplicar mètodes d'Intel·ligència artificial, cal tenir una intuïció sobre com influeixen les variables observacionals el resultat. A partir de la descripció de les variables escriu breument la llista de variables que poden augmentar o

disminuir el temps de supervivència. Redactar una explicació d'una línia per justificar cada cas.

2.0. Regressió Logística: Una Introducció Intuïtiva

- Volem una variable indicadora $chd = \{+1, -1\}$ que digui presència o absència:
 - **Fórmula de la Regressió Logística:** $chd = f(X_1, X_2 + \dots, X_n)$


On:

- $f(\cdot)$ és binària.


2.1. Hipotesi sobre la distribució de la Variable CHD en funció d'altres variables.

Probabilitat condicionada:

$P(chd = 1/\{\text{alcohol}, \text{edat}\})$ i $P(chd = 0/\{\text{alcohol}, \text{edat}\})$



Distribucions gaussianes en 3D



Explicació

1. Distribucions Gaussians $P(\text{chd} = 1/\{\text{alcohol}, \text{edat}\})$ i $P(\text{chd} = 0/\{\text{alcohol}, \text{edat}\})$:

- Es defineixen dos grups de població:
 - Grup 1:** Representa individus amb **chd = 1** (presència de malaltia coronària). S'assigna una gaussiana amb mitjana $m1 = [1, 1]$, on 1 en alcohol i 1 en edat podrien indicar nivells moderats d'alcohol i una certa edat que es relacionen amb un risc major de CHD.
 - Grup 2:** Representa individus amb **chd = 0** (absència de malaltia coronària). S'assigna una gaussiana amb mitjana $m2 = [-1, -1]$, suggerint nivells més baixos d'alcohol i edat que es correlacionen amb menys risc de CHD.

2. Paràmetres:

- Mitjanes ($m1$ i $m2$):** La mitjana controla on es concentra la major densitat de probabilitat per a cada grup en l'espai bidimensional d'alcohol i edat.
- Matriu de covariància (s):** La mateixa per a ambdues distribucions, suggerint que la variabilitat i la correlació entre alcohol i edat és similar en

ambdues poblacions.

3. Figura:

- Es fan servir línies de contorn per mostrar les densitats de probabilitat de les distribucions gaussianes en un pla bidimensional, amb:
 - **Verd** per a la distribució amb CHD, indicant on és més probable trobar individus amb malaltia coronària.
 - **Vermell** per a la distribució sense CHD, indicant on és més probable trobar individus sans en aquest context.

4. Interpretació de les Gràfiques:

- La gràfica de l'esquerra (amb mitjana [1,1]) podria suggerir que individus amb un consum moderat d'alcohol i una edat avançada tenen un risc elevat de CHD.
- La gràfica de la dreta (amb mitjana [-1,-1]) podria indicar que menys consum d'alcohol i menys edat s'associen amb menys probabilitat de CHD.

Aquest model simplifica la realitat molt; en la pràctica, CHD està influenciada per molts més factors que només alcohol i edat. Així, aquest exemple serveix més com una il·lustració conceptual de com podríem modelar hipòtesis sobre la distribució de poblacions en relació amb una malaltia, usant estadístiques.


Funció que indica la certesa $P(chd = 1/\{alcohol, edat\})$.

Observar que: $P(chd = 0/alcohol, edat) = 1 - P(chd = 1/alcohol, edat)$


5. **Esquerra:** Observar encavalcament entre distribucions, i recta que passa per la regió d'igual probabilitat

Dreta: Funció que indica probabilitat de $chd = 1$


$$P(chd = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \cdot Alcohol + \beta_2 \cdot Edat)}}$$




$$P(\text{chd} = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \cdot \text{Alcohol} + \beta_2 \cdot \text{Edat})}}$$



6. Representació de les regions d'igual probabilitat vs funció logística.



Frontera de decisió de la regressió logística: $P(Y = 1|X) = \sigma(\beta_0 + \beta_1 \text{Alcohol} + \beta_2 \text{Edat})$



Exercici 2

1. Per tal de clarificar els conceptes, faci un resum d'un paràgraf amb diagrames explicant les idees anteriors.

2.2. Definició formal de la regressió logística

La regressió logística és un mètode estadístic per predir classes binàries. La variable objectiu o d'outcome és binària, és a dir, només hi ha dos resultats possibles. Per exemple, en proves mèdiques, el resultat pot ser "risc de chd" o "ausència de risc".

El model de regressió logística estima les probabilitats que una observació pertanyi a una de les dues classes. La probabilitat del resultat es modela com una funció d'una combinació lineal de variables explicatives, es a dir:

$$cdh = f(\beta_0 + \beta_1 \cdot \text{Alcohol} + \beta_2 \cdot \text{Edat})$$

La funció logística $f()$, també anomenada funció sigmoide, i.e. $\frac{1}{1+e^{-x}}$, s'utilitza per modelar la probabilitat de la classe per defecte.

- La regressió logística té la següent fórmula:

$$P(Y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}$$

On:

- $P(Y = 1)$ és la probabilitat que es produeixi l'esdeveniment.
- e és la base dels logaritmes naturals.
- β_0 és el terme de risc base, en ausència d'observacions.
- $\beta_1, \beta_2, \dots, \beta_n$ són els coeficients per a les variables explicatives $X_1, X_2, \dots, X_n$.

3. Part pràctica.

- Primer carreguem les llibreries de python
- Després carreguem la base de dades

```
In [1]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
from scipy.stats import multivariate_normal
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import classification_report, confusion_matrix
from mpl_toolkits.mplot3d import Axes3D
```

Lectura de la base de dades.

```
In [2]: file_path = 'SAHeart.csv'
heart_data = pd.read_csv(file_path)

# Visualització les primeres mostres del conjunt de dades

heart_data.drop(columns = ['row.names'], inplace = True)
heart_data.head()
```

Out [2]:

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
0	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
1	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
2	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0
3	170	7.50	6.41	38.03	Present	51	31.99	24.26	58	1
4	134	13.60	3.50	27.78	Present	60	25.99	57.34	49	1

Fem una inspecció de la base de dades, i mirem si hem de corregir algun format de dades.

In [3]:

```
print('\n Columnes/variables\n ', '_'*40)
print(list(heart_data.columns))
print('\n \n Tipus de dades de les Columnes/variables\n ', '_'*40)
print(heart_data.info())
```

Columnes/variables

```
['sbp', 'tobacco', 'ldl', 'adiposity', 'famhist', 'typea', 'obesity', 'alcohol', 'age', 'chd']
```

Tipus de dades de les Columnes/variables

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 462 entries, 0 to 461
Data columns (total 10 columns):
#   Column      Non-Null Count  Dtype
---  -
0    sbp         462 non-null    int64
1    tobacco     462 non-null    float64
2    ldl         462 non-null    float64
3    adiposity   462 non-null    float64
4    famhist     462 non-null    object
5    typea       462 non-null    int64
6    obesity     462 non-null    float64
7    alcohol     462 non-null    float64
8    age         462 non-null    int64
9    chd         462 non-null    int64
dtypes: float64(5), int64(4), object(1)
memory usage: 36.2+ KB
None
```

Veurem valors de la variable categòrica

In [4]:

```
print('\n \n Valors de la variable categorica, "family history"\n ', '_'*40)
print(heart_data.famhist.unique())
```

Valors de la variable categorica, "family history"

```
['Present' 'Absent']
```

Corregim les dades que no són float i el codi de "famhist".

```
In [5]: # Transformem 'famhist' en una variable binària
# Aquí 'Present' es converteix en 1 i 'Absent' en 0
heart_data['famhist'] = heart_data['famhist'].map({'Present': 1, 'Absent': 0})

# Convertim 'typea', 'age' i 'chd' en tipus float
# Això assegura que les columnes siguin tractades com a nombres de coma flotant
heart_data['typea'] = heart_data['typea'].astype(float)
heart_data['age'] = heart_data['age'].astype(float)
heart_data['chd'] = heart_data['chd'].astype(float)

# Mostrem les primeres files per verificar els canvis
heart_data.head()
```

```
Out [5]:
```

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
0	160	12.00	5.73	23.11	1	49.0	25.30	97.20	52.0	1.0
1	144	0.01	4.41	28.61	0	55.0	28.87	2.06	63.0	1.0
2	118	0.08	3.48	32.28	1	52.0	29.14	3.81	46.0	0.0
3	170	7.50	6.41	38.03	1	51.0	31.99	24.26	58.0	1.0
4	134	13.60	3.50	27.78	1	60.0	25.99	57.34	49.0	1.0

Exercici 3

1. Expliqui breument el que fa els mètodes "map" i "astype"

Estadístiques descriptives per a les columnes numèriques

```
In [6]: # Estadístiques descriptives per a les columnes numèriques
heart_data.describe().round(2)
```

```
Out [6]:
```

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
count	462.00	462.00	462.00	462.00	462.00	462.00	462.00	462.00	462.00	462.00
mean	138.33	3.64	4.74	25.41	0.42	53.10	26.04	17.04	42.00	0.42
std	20.50	4.59	2.07	7.78	0.49	9.82	4.21	24.48	14.00	0.50
min	101.00	0.00	0.98	6.74	0.00	13.00	14.70	0.00	15.00	0.00
25%	124.00	0.05	3.28	19.77	0.00	47.00	22.98	0.51	31.00	0.00
50%	134.00	2.00	4.34	26.12	0.00	53.00	25.80	7.51	45.00	0.00
75%	148.00	5.50	5.79	31.23	1.00	60.00	28.50	23.89	55.00	0.00
max	218.00	31.20	15.33	42.49	1.00	78.00	46.58	147.19	64.00	1.00

Exercici 4

1. Observar que la mitjana aritmètica i mediana (percentil 50%) d'algunes variables són diferents, i les desviacions estandard són molt semblants a les mitjanes. Es

coherent amb una distribució Gausiana?, Quina distribució estadística coneix que tingui aquesta propietat?

- **Atenció:** aquest apartat servirà per interpretar mes endavant la figura: Box Plot (diagrama en capces).

3.1 Recordatori: Anàlisi Exploratòria de Dades (EDA)

- **Estadístics Descriptiu:**

- **Mitjana:** $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- **Mediana:** El valor del mig (percentil 50%) quan les dades estan ordenades.
- **Moda:** El valor més freqüent.
- **Desviació Estàndard:** $\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$
- **Quartils:** Valors que divideixen les dades en els valors per sota un percentil (min, 25%, 50%, 75%).
 - **Q1:** Percentil 25
 - **Q2:** Percentil 50 (mediana)
 - **Q3:** Percentil 75
- **Rang Interquartílic (IQR):** Q3 - Q1

- **Quantils**

- Els quantils són punts de tall que divideixen l'abast d'una distribució de probabilitat en intervals continus amb probabilitats iguals. Hi ha diversos tipus de quantils, però els més comuns són els quartils (que divideixen les dades en quarts).

El k-èsim quantil es pot calcular amb la fórmula: $Q_k = \frac{k(N+1)}{4}$

per a $k = 1, 2, \dots, N$ on Q_k és el k-èsim quantil i N és el nombre d'observacions.

Figures

- **Histograma:** Una representació gràfica de la distribució d'una variable numèrica. Mostra la freqüència d'aparició de diferents valors dins de rangs especificats.
- **Diagrama de Caixes (Box Plot):** Una manera estandarditzada de mostrar dades basada en un resum de cinc valors descriptius: mínim, primer quartil (Q1), mediana (Q2), tercer quartil (Q3) i màxim. Els diagrames de caixes són útils per identificar valors atípics i comparar distribucions.

Recordar que EDA és important per a **l'informe Final i Recomanacions** que es presenten al final dels estudis.

3.2.1 Histograma (distribució de prob.).

- Nota: fem servir la llibria "seaborn" (<https://seaborn.pydata.org/examples>)

• Histograma

- Un histograma és una representació aproximada de la distribució de dades numèriques. Va ser introduït per primera vegada per Karl Pearson. Per construir un histograma, el primer pas és "classificar" l'abast dels valors, és a dir, dividir l'abast complet dels valors en una sèrie d'interval, i després comptar quants valors cauen en cada interval.

- **Definició formal Histograma:** $\sum_{i=1}^n f(x_i)$

on $f(x_i)$ és la freqüència d'aparició del valor x_i en el conjunt de dades.

```
In [7]: # Suposem que heart_data és el teu DataFrame
columns_to_plot = ['sbp', 'tobacco', 'ldl', 'adiposity', 'famhist', 'type']

# Configurem el gràfic
fig, axes = plt.subplots(2, 5, figsize=(20, 10))
fig.suptitle('Distribucions dels Predictors de Malalties Cardíacues', fontweight='bold')


# Aplanem els eixos per facilitar l'iteració
axes = axes.ravel()

# Bucle per cada columna per crear un gràfic
for i, col in enumerate(columns_to_plot):
    if heart_data[col].dtype == 'object':
        # Per a dades categòriques com 'famhist', usem countplot
        sns.countplot(data=heart_data, x=col, ax=axes[i])
    else:
        # Per a dades numèriques, usem histograma
        sns.histplot(data=heart_data, x=col, ax=axes[i], kde=True)

    # Rotem les etiquetes de l'eix X per una millor visibilitat si és nec
    axes[i].tick_params(axis='x', rotation=45)
    axes[i].set_title(f'Distribució de {col}')

# Ajustem el disseny per evitar solapaments
plt.tight_layout()

# Mostrem el gràfic
plt.show()
```



Exercici 6

1. Expliqueu amb paraules (tres línies) el que enteneu per valor mitjà, mediana i desviació estàndard i perquè en casos no gausians una descripció per percentils pot ser millor.
2. Expliqueu, a partir dels histogrames quina distribució de probabilitat és més adient per cada variable {Gausiana, laplace, uniforme, binomial}.
3. **Optatiu:** Explicar el software i anotar si hi ha alguna instrucció nova que hagueu après.

3.2.2 Box Plot.

Resum de cinc cinc valors descriptius: mínim, primer quartil (Q1), mediana (Q2), tercer quartil (Q3) i màxim.

```
In [8]: # Seleccionar les columnes per al boxplot
columns = ['sbp', 'tobacco', 'ldl', 'adiposity', 'typea', 'obesity', 'alcohol', 'age', 'chd']


# Crear una figura i un eix per a la visualització
plt.figure(figsize=(10, 8))

# Utilitzar Seaborn per fer un boxplot de les columnes seleccionades
sns.boxplot(data=heart_data[columns])

# Afegir títol i etiquetes als eixos
plt.title('Boxplot de les Variables del Cor')
plt.xlabel('Variables')
plt.ylabel('Valors')

# Rotar les etiquetes de l'eix X per millorar la llegibilitat
plt.xticks(rotation=45)

# Mostrar el gràfic
plt.tight_layout()
plt.show()
```



Exercici 7

Objectiu d'aquest exercici: Entendre la informació proporcionada pel BoxPlot.

Recordar que serveix per donar una idea de les fites importants de la distribució de probabilitat de la variable.

1. Descriu amb paraules per cada variable (una o dues línies), la informació que dona el box plot. Què vol dir que una observació estigui a més de 1,5 vegades la desviació estàndard (valor extrem)? Com es veu que la distribució és asimètrica?

```
In [9]: # Desequilibris en les característiques categòriques
for col in ['famhist', 'chd']:
    print(f"Distribució de valors a {col}: (percentatge)")
    print(f'{heart_data[col].value_counts(normalize=True).round(4)*100}')
```

Distribució de valors a famhist: (percentatge)

famhist

0 58.44

1 41.56

Name: proportion, dtype: float64

Distribució de valors a chd: (percentatge)

chd

0.0 65.37

1.0 34.63

Name: proportion, dtype: float64

Exercici 8

Conseqüència del desequilibri:

1. Proposi un clasificador per **chd** que necessita una línia de codi i proporciona un **65.37%** d'encerts.

4.0. Recordatori: Definició formal de la Funció de Correlació

El coeficient de correlació entre dues variables X i Y és el coeficient de correlació de Pearson r , que es calcula com:


$$r_{X,Y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

On:


- n és el nombre de parells de puntuacions.
- X_i i Y_i són els punts de mostra individuals indexats amb i .
- $\bar{X}$ i $\bar{Y}$ són les mitjanes de X i Y , respectivament.

5. Interpretació del signe de la correlació:

- $r_{X,Y} > 0$: Les variables es mouen en la mateixa direcció (correlació positiva).
- $r_{X,Y} < 0$: Les variables es mouen en direccions oposades (correlació negativa).
- $r_{X,Y} = 0$: No hi ha cap relació lineal entre X i Y .
- Exemple $r_{X,Y} > 0$:



- Exemple $r_{X,Y} = 0$:




Exercici 9

1. Descriu amb paraules, a partir de la figura superior, els passos que es segueixen en el càlcul de la funció de correlació. Expliqui què pot significar que $(X_i - \bar{X})(Y_i - \bar{Y})$ tingui signes alternats i com això pot afectar el valor del coeficient de correlació $r_{X,Y}$.

4.1. Calcularem la matriu de correlació entre variables numèriques.

```
In [10]: # Matriu de correlació
plt.figure(figsize=(12, 10))
corr_matrix = heart_data.corr()
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm')
plt.title('Matriu de correlació')
plt.show()
```



Exercici 10

A partir de l'explicació del coeficient de correlació de Pearson, i el significat de les variables.


1. Expliqui que significa que **chd** estigui correlada positivament amb el edat i tabac, i pràcticament incorrelada amb alcohol i obesitat.

2. Expliqui que significa que el nivell de colesterol estigui negativament correlat amb el consum d'alcohol i positivament correlat amb tabac i pressió sanguínea alta. Faci servir els diagrames de dispersió de l'explicació de $r_{X,Y}$

4.2. Regressió no estandard

Ranking de la correlació de les variables amb chd

```
In [11]: f, ax = plt.subplots(figsize=(7, 6))
ax = corr_matrix['chd'].iloc[:-1].sort_values(ascending=False).plot.bar()
plt.title('Correlació malaltia cardíaca amb altres variables.')
ax.xaxis.grid(True)
ax.yaxis.grid(True)
ax.set(ylabel="Correlació")
plt.show()
```



Exercici 11

Regressió no estandard.

- **Nota:** Es fa servir molt sovint, quan s'enten el problema de forma qualitativa i no es vol resoldre el problema de trobar els coeficients amb mínims quadràtics.
(!!!!)

- De forma qualitativa i amb coeficients pensats a partir de la figura anterior, proposar valors $\beta_0, \beta_1, \beta_2, \dots, \beta_n$ per cada variable per obtenir un estimador qualitatiu del tipus:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

4.3. Histogrames de les variables condicionats per la condició chd

```
In [12]: fig, axes = plt.subplots(1, 4, figsize=(20, 5))


# Per a 'age'
sns.histplot(data=heart_data, x='age', hue='chd', kde=True, ax=axes[0])
axes[0].set_title('Distribució de edat segons chd')

# Per a 'tobacco'
sns.histplot(data=heart_data, x='tobacco', hue='chd', kde=True, ax=axes[1])
axes[1].set_title('Distribució de consum de tabac segons chd')

# Per a 'famhist'
sns.histplot(data=heart_data, x='famhist', hue='chd', kde=True, ax=axes[2])
axes[2].set_title('Distribució de famhist segons chd')

# Per a 'ldl'
sns.histplot(data=heart_data, x='ldl', hue='chd', kde=True, ax=axes[3])
axes[3].set_title('Distribució de ldl (colesterol) segons chd')

# Ajustem el layout per evitar solapes
plt.tight_layout()
plt.show()
```



Exercici 12


- Expliqui en un paràgraf el increment en risc relacionat amb edat, tabac, antecedents familiars, i colesterol.

4.4. Relació de comportament tipus "A" amb altres observacions.

Definició de Comportament de Tipus A

Aquest comportament està caracteritzat per: a) Ambició intensa, b) Impaciència, c) Competitivitat, d) Tendència a la hostilitat, e) Pressió per aconseguir moltes coses en poc temps

```
In [13]: f, ax = plt.subplots(figsize=(7, 6))
ax = corr_matrix['typea'].sort_values(ascending=False).iloc[1:].plot.bar(
plt.title('Correlació comportament "tipus A" amb altres variables.')
ax.xaxis.grid(True)
ax.yaxis.grid(True)
ax.set(ylabel="Correlació")
plt.show()
```




Exercici 13

1. Expliqui en un paràgraf el increment en risc donat per la personalitat en quan a diversos factors. Es un bon predictor de **chd**?, Hi ha component familiar?

4.4. Explicació dels Diagrames de dispersió.

Exemple: Edat vs. colesterol (ldl)

```
In [14]: Columns = [ 'age', 'ldl' ]
sns.pairplot(heart_data, hue = 'chd', vars=Columns)
plt.show()
```




Explicació del diagrama anterior

- Eix X L'eix X representa l'**edat dels pacients**. Els valors d'edat s'estenen al llarg de l'eix horitzontal, indicant el rang d'edats en el conjunt de dades.
- Eix Y L'eix Y representa els **nivells de colesterol sèric** en mil·ligrams per decilitre (mg/dl). Els nivells de colesterol s'estenen al llarg de l'eix vertical, indicant el rang de nivells de colesterol presents en el conjunt de dades.
- Punts de dades i segmentació per color Cada punt del gràfic representa l'**edat i el nivell de colesterol d'un pacient** segmentat per presència de malaltia chd = 1 (taronja) o absència chd = 0 (blau).

4.4.1. Diagrames de dispersió de les variables mes correlades amb la malaltia cardíaca

a) tobacco, b) ldl (colesterol) c) adiposity, d) famhist, e) age **Nota:** el diagrama de dispersió condicionat (colors diferents) per presència/ausència de malaltia cardíaca, permet entendre com són de predictives les variables. Observar els histogrames


```
In [15]: Columns = ['tobacco', 'ldl', 'adiposity', 'famhist', 'age']
sns.pairplot(heart_data, hue = 'chd', vars=Columns)
plt.show()
```



Exercici 14

1. Expliqui en un paràgraf com interpretar el diagrama anterior i com es pot utilitzar per entendre les relacions entre variables? Pista, observar que hi ha regions amb més densitat de punts d'un color que altres.

```
In [16]: # Creating a scatter plot using Seaborn
sns.scatterplot(data = heart_data, x='adiposity', y='ldl', hue = 'chd')
plt.title('Scatter Plot of Age vs. Serum Cholesterol')
plt.xlabel('adiposity')
plt.ylabel('Serum Cholesterol (mg/dl)')
plt.show()
```



5.0. Creació del clasificador basat en regressió logística.

5.1. Justificació de la partició entre entrenament i test en Machine Learning

Divisió de dades en ML

En **Machine Learning**, dividim les dades en **entrenament** i **test** per:

1. **Evitar sobreajustament** - Prevenir que el model aprengui patrons específics en lloc de generalitzar.
2. **Estimar rendiment** - Avaluar com el model funcionarà amb dades no vistes.
3. **Validar el model** - Comparar models i ajustar hiperparàmetres objectivament.
4. **Reduir biaixos** - Assegurar una avaluació sense inflar el rendiment.

```
In [17]: Variables = ['sbp', 'tobacco', 'ldl', 'adiposity', 'famhist', 'typea', 'o
          'alcohol', 'age']
Objectiu = ['chd']
X = heart_data[Variables].copy()
y = heart_data[Objectiu].copy()
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,

# Mostra les dimensions dels conjunts resultants
print("X_train shape:", X_train.shape) # Dimensions del conjunt d'entren
print("X_test shape:", X_test.shape)   # Dimensions del conjunt de test
```

```
print("y_train shape:", y_train.shape) # Dimensions del conjunt d'entrenament
print("y_test shape:", y_test.shape)   # Dimensions del conjunt de test
```

```
X_train shape: (369, 9)
X_test shape: (93, 9)
y_train shape: (369, 1)
y_test shape: (93, 1)
```

5.2. Justificació de l'estandardització en Machine Learning

L'estandardització és important en ML per:

1. **Normalització** - Fer independent de l'escala (km, cm, kg, gm, etc.).
2. **Evitar biaixos** - Mitigar influències desiguals de característiques amb diferents escales.

La fórmula és:

$$z = \frac{x - \mu}{\sigma}$$

On:

- x : valor de la variable.
- μ : mitjana (entrenament).
- σ : desviació típica (entrenament).
- z : valor estandarditzat.

Nota: Calcular μ i σ només amb dades d'entrenament per evitar *data leakage*.

```
In [18]: scaler = StandardScaler()
X_train = X_train.to_numpy()
X_test = X_test.to_numpy()
X_scaled = scaler.fit_transform(X_train)
X_scaled_test = scaler.transform(X_test)
```

```
In [19]: print("Valors abans d'estandaritzar")
pd.DataFrame(X_train, columns = X.columns).describe().round(1).iloc[1:]
```

Valors abans d'estandaritzar

```
Out[19]:
```

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age
mean	138.0	3.6	4.8	25.1	0.4	53.3	26.0	15.3	42.8
std	20.3	4.5	2.1	7.6	0.5	10.0	4.3	22.0	14.8
min	102.0	0.0	1.0	6.7	0.0	13.0	14.7	0.0	15.0
25%	124.0	0.0	3.3	19.5	0.0	47.0	22.9	0.5	31.0
50%	134.0	2.0	4.4	25.9	0.0	54.0	25.8	6.5	44.0
75%	148.0	5.5	5.6	30.7	1.0	60.0	28.4	21.6	56.0
max	216.0	31.2	15.3	42.5	1.0	78.0	46.6	147.2	64.0

```
In [20]: print("Valors després d'estandaritzar")
```

```
pd.DataFrame(X_scaled, columns = X.columns).describe().round(1).iloc[1:]
```

Valors després d'estandaritzar

Out [20]:	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age
mean	0.0	-0.0	0.0	-0.0	0.0	-0.0	0.0	0.0	-0.0
std	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
min	-1.8	-0.8	-1.8	-2.4	-0.8	-4.0	-2.6	-0.7	-1.9
25%	-0.7	-0.8	-0.7	-0.7	-0.8	-0.6	-0.7	-0.7	-0.8
50%	-0.2	-0.3	-0.2	0.1	-0.8	0.1	-0.1	-0.4	0.1
75%	0.5	0.4	0.4	0.7	1.2	0.7	0.5	0.3	0.9
max	3.9	6.1	5.0	2.3	1.2	2.5	4.8	6.0	1.4

Exercici 19

- Per aclarir idees, expliqui un parell de línies,
 - Per què s'ha fet la divisió entre train i test?
 - Les diferències entre estandaritzar i no estandaritzar en quan a valor mig, desviació estandard, i rang interquantil.

5.3. Estimació dels paràmetres de la regressió logística.

- `log_reg = LogisticRegression(max_iter=1000)`: inicialitza un model de regressió logística amb un màxim de 1000 iteracions per a la convergència.
- `log_reg.fit(X_train, y_train.values.ravel())`: entrena el model amb les dades d'entrenament `X_train` i les etiquetes `y_train` (aplana les etiquetes amb `.ravel()`).
- `y_pred = log_reg.predict(X_test)`: Futilitza el model entrenat per predir els resultats per a les dades de test `X_test` i assigna aquestes prediccions en `y_pred`.

```
In [21]: log_reg = LogisticRegression(max_iter=1000)

log_reg.fit(X_train, y_train.values.ravel())

y_pred = log_reg.predict(X_test)
```

comparació de la referència `y_test` amb la predicció `y_pred`

```
In [22]: pd.DataFrame({'y_test':y_test.values.ravel(), 'y_pred':y_pred}).T
```

```
Out [22]:
```

	0	1	2	3	4	5	6	7	8	9	...	83	84	85	86	87	8
y_test	0.0	1.0	1.0	0.0	0.0	0.0	0.0	1.0	0.0	1.0	...	0.0	0.0	0.0	0.0	1.0	0.
y_pred	0.0	0.0	1.0	1.0	0.0	0.0	0.0	0.0	1.0	1.0	...	0.0	0.0	0.0	0.0	0.0	1.

2 rows x 93 columns

5.3. Avaluació del Model

Paràmetres d'Avaluació de la qualitat del model

1. Precisió (Precision)

Definició: La precisió és la relació entre les instàncies predites correctament i el total d'instàncies en el conjunt de dades. Mesura l'efectivitat general del model.

$$\text{Precisió} = \frac{VP + VN}{VP + VN + FP + FN}$$

On:

- VP = Veritables Positius
- VN = Veritables Negatius
- FP = Falsos Positius
- FN = Falsos Negatius

2. Sensibilitat (Recall)

Definició: La sensibilitat, també coneguda com a recall, és la relació entre les observacions positives predites correctament i tots els positius reals. Mesura la capacitat del model per identificar instàncies positives.

$$\text{Sensibilitat} = \frac{VP}{VP + FN}$$

On:

- VP = Veritables Positius
- FN = Falsos Negatius

3. Puntuació F1 (F1-Score)

Definició: La puntuació F1 és la mitjana harmònica de l'exactitud i la sensibilitat. Proporciona un equilibri entre les dues mètriques, especialment en conjunts de dades desequilibrats.

$$\text{Puntuació F1} = 2 \times \frac{\text{Exactitud} \times \text{Sensibilitat}}{\text{Exactitud} + \text{Sensibilitat}}$$

4. Suport (Support):

Definició: El suport és el nombre d'ocurrències de cada classe en el conjunt de dades de test. Reflecteix la quantitat de dades disponibles per a cada classe per avaluar el rendiment del model.

$$Suport = TP + FN$$

On:

- **TP:** Nombre d'instàncies que són de la classe i han estat correctament predites com a tals.
- **FN:** Nombre d'instàncies de la classe que han estat incorrectament predites com a no pertanyents a la classe.

```
In [23]: print("Informe de Classificació:")
report = classification_report(y_test, y_pred, output_dict=True)
df_report = pd.DataFrame(report).transpose()
df_report.iloc[:-3]
```

Informe de Classificació:

```
Out[23]:
```

	precision	recall	f1-score	support
0.0	0.776119	0.881356	0.825397	59.0
1.0	0.730769	0.558824	0.633333	34.0

Exercici 20

1. En base a les definicions anteriors donar una explicació en un paràgraf del informe de classificació. Valori les prestacions del classificador.

Matriu de Confusió

Definició: Una matriu de confusió és una taula que s'utilitza per avaluar el rendiment d'un model de classificació. Resumeix el recompte de prediccions de veritables positius, veritables negatius, falsos positius i falsos negatius.

	Predicció Positiva	Predicció Negativa
Real Positiu	VP	FN
Real Negatiu	FP	VN

```
In [24]: # Confusion matrix
print("Matriu de Confusió:")
cm = confusion_matrix(y_test, y_pred)
df_cm = pd.DataFrame(cm,
                      index=['Real Positiu', 'Real Negatiu'],
                      columns=['Predicció Positiva', 'Predicció Negativa'])

df_cm
```

Matriu de Confusió:

Out [24]:

	Predicció Positiva	Predicció Negativa
Real Positiu	52	7
Real Negatiu	15	19

Exercici 21

1. En base a les definicions anteriors donar una explicació en un paràgraf de la Matriu de Confusió. Valori les prestacions del classificador.

Definició de la Corba ROC (Receiver Operating Characteristic)

La **Corba de Característica de Funcionament del Receptor (ROC)** és una eina gràfica utilitzada per avaluar la capacitat d'un classificador binari de discriminar entre classes positives i negatives. La corba es construeix traçant la **Taxa de Veritables Positius (TPR)** contra la **Taxa de Falsos Positius (FPR)** a diferents nivells de llindar de classificació.

- **Taxa de Veritables Positius (TPR):** També coneguda com a **sensibilitat o recall**, és la proporció d'instàncies positives que han estat correctament identificades.
 - **Fórmula:** $TPR = VP / (VP + FN)$, on VP és Veritables Positius i FN és Falsos Negatius.
- **Taxa de Falsos Positius (FPR):** És la proporció d'instàncies negatives que han estat incorrectament classificades com a positives.
 - **Fórmula:** $FPR = FP / (FP + VN)$, on FP és Falsos Positius i VN és Veritables Negatius.

Com interpretar la Corba ROC:

- **Taxa de Falsos Positius (FPR):** Representa la taxa d'error de tipus I (falsos positius). Com més baixa sigui aquesta taxa, millor és el model a l'hora de no classificar falsament negatives com a positives.
- **Taxa de Veritables Positius (TPR):** Representa la sensibilitat del model. Una TPR alta indica que el model és bo per identificar veritables positius.
- **Línia de referència:** La línia de punts (o línia diagonal) representa un classificador aleatori. Si la corba ROC del model està per sobre d'aquesta línia, el model té una capacitat de predicció millor que l'atzar.
- **Àrea sota la Corba (AUC):**
 - Un AUC de 1 indica un classificador perfecte.

- Un AUC de 0.5 suggereix que el model està predint a l'atzar (equivalent a la línia diagonal).
- Un AUC menys de 0.5 implicaria que el model està predint pitjor que l'atzar.


Quan més s'apropa la corba ROC a l'eix superior esquerre del gràfic, més bo és el model, ja que això significa que és capaç d'aconseguir una alta taxa de veritables positius amb una taxa de falsos positius baixa. L'AUC proporciona una mesura agregada de la rendiment del model a través de tots els possibles punts de tall.

```
In [25]: from sklearn.metrics import roc_curve, auc

# Obtenim les probabilitats per a la classe 1
y_pred_proba = log_reg.predict_proba(X_test)[:, 1]

# Calculem la corba ROC i l'àrea ROC
fpr, tpr, _ = roc_curve(y_test, y_pred_proba)
roc_auc = auc(fpr, tpr)

# Traçem la corba ROC
plt.figure()
plt.plot(fpr, tpr, color='darkorange', lw=2, label=f'Corba ROC (àrea = {roc_auc:.2f})')
plt.plot([0, 1], [0, 1], color='navy', lw=2, linestyle='--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('Taxa de Falsos Positius')
plt.ylabel('Taxa de Veritables Positius')
plt.title('Corba de Característica de Funcionament del Receptor (ROC)')
plt.legend(loc="lower right")
plt.show()
```



Exercici 21

1. En base a les definicions anteriors donar una explicació en un paràgraf de la corba ROC. Valori les prestacions del classificador.

Informe Final i Recomanacions

1. Informe on es relaciona la informació obtinguda amb l'estudi fet amb l'EDA amb els resultats obtinguts pel mètode de machine learning.
2. Recomanacions per millorar el sistema i implementar-lo.